

Seguridad y Resiliencia

Minimización de datos, rutas de error y puntos de Human-in-the-Loop del workflow

1. Minimización de datos

El formulario de origen pide solo lo indispensable para atender un reclamo: nombre, email, categoría del problema y el mensaje del cliente. No se recolecta ningún dato sensible ni innecesario (sin medios de pago, domicilio, teléfono, documento de identidad). A partir de ahí, cada integración del workflow recibe únicamente los campos que necesita para cumplir su función — ninguna recibe el ticket completo por defecto.

Destino	Campos que recibe	Campos que NO recibe
Claude Haiku (clasificación)	Categoría declarada por el cliente + mensaje.	Nombre y email del cliente — la clasificación no los necesita.
Claude Sonnet (redacción)	Nombre, categoría IA, urgencia IA, mensaje.	Email del cliente — Sonnet redacta el cuerpo, no arma el envío.
Slack (HITL)	Nombre, email, categoría IA, urgencia IA, mensaje, respuesta propuesta.	— (el agente humano necesita el contexto completo para aprobar con criterio).
Gmail	Email del destinatario, texto de la respuesta.	Categoría, urgencia, mensaje original — no hacen falta para enviar el mail.
Airtable (Tickets)	Todos los campos del ticket.	— (es la fuente de verdad operativa; necesita el registro completo).

Los dos únicos modelos de IA del flujo nunca reciben el email del cliente: viaja únicamente hasta Slack (para que el aprobador pueda identificar al cliente) y hasta Gmail (para poder enviarle la respuesta). Ninguna llamada a la API de Anthropic incluye datos de contacto.

Manejo de credenciales: las cuatro integraciones (Airtable, Anthropic, Slack, Gmail) se autentican a través del sistema de credenciales nativo de n8n — `airtableTokenApi`, `httpHeaderAuth`, `slackApi` y `gmailOAuth2`, respectivamente. Ningún API key ni token aparece hardcodeado en el JSON del workflow ni en los prompts; todo secreto vive fuera del flujo, gestionado por n8n.

Alcance actual: el proyecto no implementa todavía un borrado o anonimización automática de tickets antiguos — los registros quedan en Airtable/Google Sheets sin fecha de expiración. Es una limitación conocida y una mejora natural para una versión productiva, fuera del alcance de este entregable académico.

2. Rutas de error (Error Handlers)

El workflow distingue dos tipos de "error": los rechazos de negocio esperados (datos incompletos, ticket duplicado) y las fallas técnicas de una integración externa (timeout, rate limit, error de API). Solo el segundo tipo se registra como Error — un duplicado, por ejemplo, no es una falla del sistema: se detecta con un IF y el ticket simplemente se ignora sin pasar por el Error Handler.

Las fallas técnicas se capturan con onError: continueErrorOutput en cada nodo que llama a una integración externa — la excepción no aborta la ejecución completa ni bloquea el resto de la cola, se desvía a un Code node dedicado que arma un registro estructurado ({ ticket_id, nodo_origen, tipo_error, detalle_error }), clasificando automáticamente el tipo de error a partir del mensaje (Rate limit / Timeout / API Error). Hay 7 puntos críticos cubiertos:

#	Nodo de origen	Cómo se detecta	Tipo(s) de error posibles
1	IF - Datos Completos? (rama negativa)	Rama explícita del IF — no es una excepción capturada, es un rechazo de negocio.	Validación fallida
2	Airtable - Buscar Duplicado	onError: continueErrorOutput	Rate limit / Timeout / API Error
3	Airtable - Crear Ticket	onError: continueErrorOutput	Rate limit / Timeout / API Error
4	HTTP Request - Claude Haiku	onError: continueErrorOutput	Rate limit / Timeout / API Error
5	HTTP Request - Claude Sonnet	onError: continueErrorOutput	Rate limit / Timeout / API Error
6	Slack - HITL por Aprobación	onError: continueErrorOutput	Rate limit / Timeout / API Error
7	Gmail - Enviar Respuesta	onError: continueErrorOutput	Rate limit / Timeout / API Error

Cada registro se persiste en paralelo en dos lugares: la tabla "Errores" de Airtable (vinculada a Panel KPIs, para que la tasa de error del día se calcule sola vía rollup) y la pestaña "Errores" de Google Sheets, como bitácora secundaria fuera de Airtable.

3. Puntos de Human-in-the-Loop

El sistema nunca le envía una respuesta al cliente sin que una persona la haya visto y aprobado primero. Hay tres puntos donde una decisión humana entra en el flujo:

3.1 Aprobación de la respuesta propuesta (punto primario)

Antes de enviar nada por Gmail, la respuesta redactada por Claude Sonnet se manda a un canal de Slack con la operación sendAndWait, mostrando dos botones: Aprobar y Rechazar (parámetro approvalType: "double" — se refiere al tipo de botones, no a que hagan falta dos personas distintas; con que un aprobador haga clic en cualquiera de los dos alcanza para que el workflow retome la ejecución). Si se aprueba, continúa a Gmail; si se rechaza, el mail nunca sale.

3.2 Triage manual de tickets rechazados (punto secundario)

Cuando un aprobador rechaza la respuesta propuesta, el sistema no reintenta ni improvisa una alternativa: notifica al canal de soporte y deja el ticket en Estado = Rechazado. A partir de ahí, un agente humano lo resuelve manualmente fuera del flujo automatizado — es un segundo checkpoint humano, deliberadamente fuera del alcance de la IA.

3.3 Revisión de errores registrados (punto operativo)

Todo registro que cae en la tabla "Errores" nace en Estado = Abierto. El workflow no reintenta la llamada fallida por su cuenta: queda a criterio de un humano decidir cómo proceder, y recién ahí el estado avanza a En revisión y luego a Resuelto — ese avance de estado es manual, no lo escribe n8n.

4. Otras medidas de resiliencia

- Sin bucles: el trigger dispara una ejecución por cada fila nueva del formulario (evento rowAdded), y el Loop por ticket procesa un único ítem fijo por ejecución — no hay recursión ni reprocesamiento en cadena dentro de una misma corrida.
- Sin duplicados: el ticket_id es un hash determinístico de email + marca temporal + mensaje. Si el trigger llegara a redisparar sobre la misma fila, la verificación de duplicación por Ticket ID lo detecta y el ticket se ignora en vez de generar un alta duplicada o disparar de nuevo la cadena de llamadas a la IA.
- Prompts dinámicos: ningún prompt tiene el nombre de la empresa, las categorías válidas o el modelo escritos a mano — todo se arma en tiempo de ejecución a partir de variables de n8n (\$vars), documentado en detalle en el Documento 2 (secciones 2.3 y 2.4).