

Pre-entrega Módulo 5

El Cerebro Documental de la IA (RAG)

Proyecto integrador **AgendaBot** — AI Automation Avanzado (Coderhouse)

Julio Martín Waisburd



09/10/2026

Índice

Pieza 1 — Ingesta documental con LlamaParse (LlamaCloud)	pág. 2
Pieza 2 — Recuperación: Top-K y Minimum Score	pág. 4
Pieza 3 — System Prompt RAG (citar fuentes + regla "No sé")	pág. 7
Pieza 4 — Reporte de validación (5 preguntas ciegas)	pág. 12
Pieza 5 — Plan de gobernanza de la base de conocimiento (RAG)	pág. 15

Pieza 1 — Ingesta documental con LlamaParse (LlamaCloud)

La base de conocimiento son **16 documentos institucionales** de la Clínica LoDeTincho (.docx/.doc). Se parsearon con **LlamaParse (LlamaCloud), tier Agentic**. El markdown resultante **preserva la jerarquía de títulos** (documento > sección > subsección; por ejemplo *Especialidades > Cardiología*) y **las tablas como filas y celdas** (por ejemplo, el encuadre impositivo por provincia). Ese markdown es la fuente que n8n corta **por sección**: cada fragmento lleva adelante su ruta de títulos y se vectoriza en Qdrant, con 195 fragmentos en total.



Qué se limpió antes y durante la ingesta - **Anonimización:** la marca institucional se reemplazó por "LoDeTincho" y los datos de contacto reales por los canales del proyecto (mail y chat del asistente). -

Duplicados fuera: se excluyeron el índice (`00_Indice`) y el documento consolidado (`Documentacion_Completa`), que repetían el contenido de los otros 16 y habrían generado fragmentos duplicados. - **Tablas:** LlamaParse devuelve las tablas complejas, con celdas combinadas, como HTML. El nodo de *chunking* las convierte a tabla markdown, una fila por línea, y las tablas largas se parten por filas repitiendo el encabezado. - **Control de fidelidad:** en 5 de 16 documentos el parser alteró texto: "Billinghurst" quedó como "Billinghamurst" y "lodetinho" como "lodetinho". Quedó registrado como riesgo, con su control, en el plan de gobernanza (pieza 5).

Por qué Parse y no un Data Source / Index de LlamaCloud En LlamaCloud, un *Data Source* pertenece a un *Index* gestionado (parseo + chunking + embeddings + vector store alojados por LlamaCloud). **El plan gratuito del proyecto no permite crear Index**, así que se usó el servicio **LlamaParse** del mismo LlamaCloud, que es justamente la etapa que preserva la jerarquía y las tablas, y el resto del pipeline se armó en n8n con un vector store propio (**Qdrant**). Esta decisión, además, da control directo sobre el *chunking* por sección y sobre el umbral de similitud (pieza 2), que en un Index gestionado quedan del lado del proveedor.


Cómo se ejecuta: `scripts/parse_kb.py` (API v2 de LlamaParse, tier: agentic) guarda un `.md` por documento en `kb_md/`, versionado en el repo, y `scripts/update_codenode.py` lo carga en el nodo de ingesta de n8n.

Pieza 2 — Recuperación: Top-K y Minimum Score

Configuración: Top-K = 5 y Minimum Score = 0.60 (similitud coseno, embeddings Cohere embed-multilingual-v3.0, colección Qdrant kb_lodetinho_m5).



Por qué no se usa el nodo nativo *Vector Store Retrieve Tool*

En la versión de n8n del proyecto (2.39.5), el nodo **Qdrant Vector Store** → "**Retrieve Documents (As Tool for AI Agent)**" permite fijar el **Top-K** (campo *Limit*), pero **no tiene Minimum Score**: sus únicas opciones son *Search Filter*, *Content Payload Key* y *Metadata Payload Key*. Se verificó también en el código de todos los nodos de vector store de esta versión: ninguno expone un umbral de similitud.



Para aplicar los dos parámetros que pide el criterio, la herramienta `consultar_conocimiento` del agente se implementó como un sub-workflow (`Tool1_ConsultarConocimiento (M5)`), conectado con *Call n8n Workflow Tool*. Cumple el mismo rol que el *Vector Store Retrieve Tool*, pero llama a la búsqueda de Qdrant con `limit` (Top-K) y `score_threshold` (Minimum Score), los dos visibles en un único nodo de parámetros:

consulta → Parámetros RAG (`top_k`, `min_score`) → Embedding Cohere (`search_query`) → Qdrant `/points/search` (`limit` + `score_threshold`) → fragmentos con fuente, sección y score



Por qué esos valores: calibración con datos

Antes de fijar el umbral, se corrió la herramienta **sin umbral** (Top-K = 8) con preguntas que tienen respuesta en la base y con preguntas que no la tienen:

Consulta	¿Está en la base?	Score del mejor fragmento	Fragmentos no relacionados
Profesionales de Cardiología	Sí	0.704	0.59 – 0.65
¿La maternidad tiene UCIN?	Sí	0.735	0.55 – 0.64
Camas de internación	Sí	0.716	0.52 – 0.62
Vacunas para viajar	Sí	0.692	0.42 – 0.46
Precio de una consulta particular	No	0.545	0.48 – 0.52
Estacionamiento para pacientes	No	0.541	0.49 – 0.53


- **Minimum Score = 0.60 (precisión).** En las preguntas con respuesta, el fragmento correcto supera 0.69; en las preguntas fuera de la base, el mejor fragmento no pasa de 0.55. El umbral separa los dos casos: para una pregunta sin respuesta en la base, la herramienta devuelve **0 fragmentos** y el agente responde "No sé" de forma determinista, en lugar de improvisar con fragmentos parecidos. Con un umbral de 0.50, ese ruido (0.54) entraría al contexto. Dentro del dominio, algunos fragmentos vecinos también superan 0.60 (por ejemplo, *Cirugía General* con 0.62 al preguntar por Cardiología). Ese filtrado fino no lo hace el umbral sino el agente, con la regla "no presentes lo relacionado como si fuera lo exacto".
- **Top-K = 5 (costo).** Los fragmentos útiles se concentran en las primeras 2 a 4 posiciones (por ejemplo, tomografía: 0.787 / 0.645 / 0.618 / 0.606). Con 5 queda margen para preguntas de dos partes (la de la residencia usó 2 fragmentos) sin inflar el contexto. Como los fragmentos son por sección (mediana de 226 caracteres), 5 fragmentos son unos 300 tokens por búsqueda; la herramienta responde en 0.4 a 1.9 s.
- **El costo del umbral y cómo se mitiga.** Una consulta muy corta, o un dato que vive en una tabla, puede quedar apenas por debajo de 0.60: en la validación, la primera búsqueda de "IIBB Mendoza" devolvió 0 fragmentos. En lugar de bajar el umbral (lo que dejaría entrar ruido), el agente **reformula la búsqueda una vez** con sinónimos o con el nombre del tema, y así recuperó el dato. Es una regla del system prompt (pieza 3).


Pieza 3 — System Prompt RAG (citar fuentes + regla "No sé")

El agente Agente RAG (Consultas) (Claude Sonnet 4.6) recibe las consultas que el Router clasifica como **INFO**. Su system prompt funciona como un **embudo de contención**: primero la memoria del paciente y después 5 bloques de reglas.

Bloque	Qué controla
Memoria del paciente	Inyecta la memoria de largo plazo de Airtable (estado, resumen, datos clave). Sirve solo para personalizar (saludar por el nombre) y entender repreguntas ; los datos de la clínica nunca salen de la memoria.
Rol y alcance	Responde solo con la base documental oficial, a través de la herramienta consultar_conocimiento.
1. Recuperar antes de responder	Busca antes de contestar, en cada turno : el historial sirve para entender "¿y los sábados?", no como fuente. Puede hacer una búsqueda por cada parte de una pregunta compuesta.
2. Responder solo con lo recuperado	Prohíbe completar con datos plausibles, afirmar ausencias ("no ofrecen X") y presentar lo relacionado como si fuera lo exacto. Ante fuentes en conflicto, informa ambas.
3. Regla "No sé"	Si no hay fragmentos, reformula una vez; si sigue sin resultados, responde con una frase fija y sin cita .
4. Citar la fuente	Cierra cada respuesta con [Fuente: <documento> – <sección>], tomado de los metadatos del fragmento.
5. Estilo	Rioplatense, breve, con tildes.

Además, el agente tiene su propia **memoria de sesión** (ventana de 6 mensajes, separada de la del Router), así que entiende la conversación en curso: "¿Se pueden hacer tomografías sin turno?" → "¿Y hasta qué hora los sábados?".





Contención de salida: el validador

El prompt contiene al modelo, pero no lo garantiza. Por eso cada respuesta pasa por un **validador de salida** antes de llegar al paciente:

Agente RAG → Preparar validación → Validador RAG (Claude Haiku 4.5) → Aplicar validación → chat / email

- **Preparar validación** toma la pregunta, la respuesta y **los fragmentos que la herramienta devolvió en ese turno** (el agente expone sus pasos intermedios).
- **Validador RAG** verifica que cada dato concreto (teléfonos, nombres, horarios, cifras, resoluciones) esté en esos fragmentos, que haya cita si se usaron datos y que el "No sé" no traiga datos inventados. Devuelve {"aprobado": true/false, "motivo": "..."}.
- **Aplicar validación**: si aprueba, sale la respuesta del agente; si rechaza, sale la respuesta segura ("No cuento con ese dato..."), y la respuesta bloqueada y el motivo quedan registrados para auditoría.

Texto completo del system prompt

MEMORIA DEL PACIENTE (conversaciones previas, desde Airtable)

Estado del caso: {{ \$('Preparar contexto').first().json.estado }}

Resumen de la última charla: {{ \$('Preparar contexto').first().json.last_summary }}

Datos clave: {{ \$('Preparar contexto').first().json.datos_clave }}

FIN DE LA MEMORIA

Usá la memoria y el historial de esta conversación SOLO para personalizar (por ejemplo, saludar por el nombre si lo conocés) y para entender repreguntas ("¿y a qué hora?"). Los datos sobre la clínica salen EXCLUSIVAMENTE de los fragmentos de "consultar_conocimiento", nunca de la memoria. Si la memoria está vacía, tratá al paciente como nuevo.

Sos el asistente de conocimiento de la Clínica LoDeTincho. Respondés consultas informativas de pacientes usando EXCLUSIVAMENTE la base documental oficial, a la que accedés con la herramienta "consultar_conocimiento".

1. Recuperar antes de responder

- Para toda consulta sobre la clínica, llamá primero a "consultar_conocimiento" con la pregunta del paciente (podés reformularla para que sea más precisa).
- Si la pregunta tiene varias partes, podés llamarla una vez por parte.
- Aunque el dato ya haya aparecido antes en la conversación, volvé a consultar la herramienta en cada respuesta que incluya datos de la clínica: el historial sirve para entender la pregunta (por ejemplo, "¿y los sábados?"), no como fuente. Un validador revisa cada respuesta contra los fragmentos recuperados EN ESTE TURNO: si das un dato sin haber llamado a la herramienta en este turno, la respuesta se rechaza.
- Saludos y cortesía se responden sin consultar la herramienta.

2. Responder solo con lo recuperado

- Usá únicamente datos que aparezcan textualmente en los fragmentos devueltos.
- No completes con datos plausibles: nada de teléfonos, mails, nombres, horarios, precios ni cifras que no estén en los fragmentos.
- Si preguntan por algo puntual (por ejemplo, una especialidad) y los fragmentos solo traen información relacionada pero no eso exacto, decilo; no presentes lo relacionado como si fuera la respuesta.
- No afirmes que la clínica NO ofrece algo solo porque no aparece en los fragmentos: la ausencia de un dato no es un dato; en ese caso aplicá la regla "No sé".
- Si dos fragmentos se contradicen, informá ambos valores con su fuente en lugar de elegir uno.

3. Regla "No sé"

Si la herramienta devuelve SIN_RESULTADOS, probá UNA vez más reformulando la búsqueda con sinónimos o el nombre del tema (por ejemplo "CUIT" → "datos impositivos razón social CUIT"; "precio" → "aranceles valores"). Si después de eso sigue sin resultados, o los fragmentos no contienen la respuesta, respondé exactamente:

"No cuento con ese dato en la documentación de la clínica."

y sugerí comunicarse con la Central de Turnos. En ese caso no agregues cita ni datos sacados de otros fragmentos.

4. Citar la fuente

Cerrá toda respuesta basada en la documentación con la fuente de cada dato usado, una línea por fuente, con este formato:

[Fuente: <fuente> – <sección>]

usando los campos "fuente" y "sección" del fragmento.

5. Estilo

Español rioplatense, claro y breve (hasta ~150 palabras), con tildes correctas.

Ejemplo de la regla "No sé" en funcionamiento (pregunta fuera de la base, búsqueda sin fragmentos sobre 0.60):

¿Tienen estacionamiento para pacientes? No cuento con ese dato en la documentación de la clínica. Te recomendamos comunicarte con la Central de Turnos de la Clínica LoDeTincho para consultar sobre disponibilidad de estacionamiento para pacientes.

Pieza 4 — Reporte de validación (5 preguntas ciegas)

Sistema evaluado: AgendaBot M5, de punta a punta: chat → Router (intent INFO) → Agente RAG (Claude Sonnet 4.6) → herramienta consultar_conocimiento (Qdrant, Top-K = 5, Min Score = 0.60, embeddings Cohere multilingual v3) → respuesta. **Protocolo (corrida ciega, 08/10):** 5 preguntas que **no se usaron** en la calibración del umbral ni como ejemplo en el prompt; una de ellas con respuesta **fuera de la base**. Cada respuesta se verificó contra el markdown fuente (kb_md/).

Resultados

#	Pregunta	Dato esperado (fuente)	Respuesta del RAG	Cita emitida	Resultado
1	¿Cuánto dura la residencia de Clínica Médica y cuántas vacantes tiene?	4 años; 9 vacantes (5 LoDeTincho + 4 Clínica del Sol) — <i>Residencias</i>	"4 años, en modalidad becario... 9 en total — 5 para Clínica LoDeTincho y 4 para Clínica del Sol"	Residencias — Clínica Médica; Residencias > Ingreso	✅ Correcto (pregunta de dos partes)
2	¿Hasta qué hora puedo hacerme una tomografía sin contraste un sábado?	Sáb., dom. y feriados de 08:00 a 20:00 — <i>Diagnóstico por imágenes sin turno</i>	"hasta las 20:00 hs, con ingreso desde las 08:00 hs"; aclara que con contraste requiere turno	Diagnóstico por imágenes > Horarios de atención	✅ Correcto
3	¿Quién lidera las cirugías de labio leporino en pediatría?	Dr. Ricardo Bennun — <i>Nuevas prestaciones pediátricas</i>	"liderado por el Dr. Ricardo Bennun, especialista en cirugía plástica infantil y craneofacial"	Nuevas prestaciones pediátricas; Especialidades > Cirugía Plástica y Craneofacial Pediátrica	✅ Correcto
4	¿Qué resolución aplica como agente de percepción de Ingresos Brutos en Mendoza?	R.G. (ATM) 30/99 — <i>Datos impositivos, dato en tabla</i>	"agente de percepción bajo la R.G. (ATM) 30/99... retención R.G. (ATM) 19/12"; suma el certificado de no retención 22/07–31/10/2026 (nota 10 de la tabla)	Datos impositivos > Impuestos Provinciales; Notas aclaratorias	✅ Correcto (ver análisis)
5	¿Cuál es el horario de visitas para los pacientes internados?	No está en la base	"La documentación no especifica el horario general de visitas"; menciona textualmente que el parte médico de Guardia se da de 12 a 13 h durante la visita	Preguntas Frecuentes (parte médico)	✅ Correcto (no inventó)

Métricas

- **Precisión (respuesta correcta y fiel a la fuente):** 5/5 = 100 %.
- **Fidelidad de la cita:** en 5/5 respuestas la sección citada contiene el dato usado.
- **Alucinaciones** (datos no presentes en la base): 0.
- **Contingencia:** 1/1. La pregunta fuera de la base no recibió un dato inventado.

Análisis crítico

- **#4: la recuperación de datos en tablas es frágil.** La primera búsqueda ("agente de percepción Ingresos Brutos Mendoza resolución") devolvió **0 fragmentos sobre 0.60**: un fragmento que es sobre todo una tabla genera un embedding "pobre" para una consulta corta. El dato apareció en la **reformulación** que

exige el prompt. *Mejora propuesta*: enriquecer los fragmentos de tabla con una frase descriptiva ("Tabla de resoluciones de IIBB por provincia...") o sumar búsqueda híbrida (palabras clave + vectores).

- **#4: atribución.** El agente dice "la clínica actúa como agente", pero el documento habla de **OMINT S.A. de Servicios**: la anonimización de la base quedó incompleta en *Datos impositivos*. No es una alucinación del modelo, es un defecto de la fuente, y se registró en gobernanza (pieza 5).
- **#5: la contingencia no usó la frase fija.** Respondió que el dato no está y agregó un hecho relacionado **textual** (el parte médico), con cita. Es útil y no inventa, pero se aparta del formato literal pedido. Se acepta como correcto y queda como punto de ajuste fino.
- **Hallazgos de la calibración (fuera del set ciego) que mejoraron el sistema:**
 - Ante "¿Atienden mascotas?", el agente **dedujo una ausencia** a partir de la lista de especialidades. Se agregó la regla "la ausencia de un dato no es un dato".
 - Ante "¿Cuántas camas tiene?", reportó **ambos valores en conflicto** (160 según *Institucional* y 140 según *Residencias*), cada uno con su fuente.
 - El Router mandaba consultas informativas (CUIT, veterinaria) a FUERA_DE_ALCANCE. Se agregó una definición explícita de INFO.
- **Comparación con la primera versión.** Con *chunking* genérico, sin umbral y con otro modelo, la precisión había sido 3/5: un dato de contacto inventado y una especialidad no recuperada. Los cambios que explican la mejora son el **chunking por sección** (Cardiología ahora es un fragmento propio con sus profesionales), el **Minimum Score** y las reglas de fidelidad del prompt.
- **Limitaciones de la medición.** La muestra es chica (n = 5), los LLM no son deterministas (la misma pregunta puede variar levemente) y el evaluador es el mismo autor. El plan de gobernanza fija un set ampliado y periódico.

Regresión después de sumar memoria y validador de salida (09/10)

Se agregaron al Agente RAG la memoria del paciente (largo plazo y sesión) y un **validador de salida** (pieza 3). Para comprobar que no rompieran nada, se repitieron las mismas 5 preguntas (ya no son ciegas: es una prueba de regresión) y se sumaron pruebas específicas de memoria y validación.

#	Pregunta	Resultado	Validador
1	Residencia: duración y vacantes	✅ 4 años; 9 vacantes (5 + 4)	Aprobada
2	Tomografía sin contraste un sábado	✅ hasta las 20:00 (08:00 a 20:00)	Aprobada
3	Labio leporino pediátrico	✅ Dr. Ricardo Bennun	Aprobada
4	IIBB Mendoza, agente de percepción	⚠️ Parcial: "R.G. (DGR) 19/12 y RG 30/99". Tomó la celda de la tabla resumen, que lista las dos normas juntas, y no distinguió percepción (30/99) de retención (19/12)	Aprobada
5	Horario de visitas (fuera de la base)	✅ dice que no está; agrega el dato textual del parte médico, con cita	Aprobada

Pruebas de memoria y validador

Prueba	Resultado
Personalización: "Hola, soy Carlos. ¿Se pueden hacer tomografías sin turno?"	✅ "¡Hola, Carlos! Sí, las tomografías sin contraste...", con los horarios correctos y la cita. Validador: aprobada.
Repregunta: "¿Y hasta qué hora los sábados?"	✅ Entendió que se hablaba de tomografías, volvió a buscar y respondió "hasta las 20:00 hs", con cita. Validador: aprobada.
Validador ante un dato sin respaldo (antes de la regla "buscar en cada turno")	✅ El agente respondió la repregunta con el horario tomado del historial, sin buscar. El validador la rechazó ("no hay fragmentos recuperados que respalden esta información") y salió la respuesta segura.

Lectura crítica - Precisión de la regresión: 4 correctas + 1 parcial. La #4, correcta en la corrida ciega, esta vez salió parcial: los LLM no son deterministas, y en una tabla con dos normas en la misma celda el modelo puede tomar cualquiera de las dos lecturas. - **Límite del validador:** la #4 se aprobó porque el texto respondido **sí está** en el fragmento. El validador controla **respaldo** (que el dato exista en la fuente), no **interpretación** (que se haya leído bien la tabla). *Mejora propuesta:* enriquecer los fragmentos de tabla con una frase que explicita qué columna es percepción y cuál retención (pieza 5), o pedirle al validador que compare la pregunta exacta con la columna citada. - **Falsos rechazos:** 0 de 5. El validador no bloqueó respuestas correctas. - **Costo:** una llamada extra a un modelo chico (Haiku 4.5) por consulta INFO; en la práctica suma 1 a 3 segundos por respuesta.

Pieza 5 — Plan de gobernanza de la base de conocimiento (RAG)

Base de conocimiento: 16 documentos institucionales de la Clínica LoDeTincho (sitio anonimizado). **Parseo:** LlamaParse, tier Agentic → markdown versionado en kb_md/. **Indexado:** n8n, un fragmento por sección → embeddings Cohere embed-multilingual-v3.0 → **Qdrant persistente**, colección kb_lodetinho_m5 (195 fragmentos). **Recuperación:** Top-K = 5, Minimum Score = 0.60. **Generación:** Claude Sonnet 4.6, con memoria del paciente. **Validación de salida:** Claude Haiku 4.5.

Objetivo: mantener la base **vigente, consistente y verificable**, y definir **cada cuánto se revisa, quién es responsable y con qué criterio se da de baja o se reemplaza un documento**.

1. Roles y responsabilidades

Rol	Responsable	Función
Dueño del conocimiento	Referente administrativo/clínico de la institución	Aprueba qué entra a la base, valida la exactitud y autoriza bajas y reemplazos. Es la fuente de verdad ante conflictos.
Curador técnico	Responsable del flujo n8n	Ejecuta el parseo y la re-ingesta, controla el <i>chunking</i> , el Top-K, el Min Score y el system prompt, y corre las validaciones.
Revisor de calidad	Rotativo (puede ser el curador)	Corre el set de preguntas ciegas, registra la precisión y las alucinaciones, y abre acciones correctivas.
Responsable de seguridad	Referente de sistemas	Gestiona credenciales y API keys, accesos y anonimización.

2. Cadencia de revisión

Qué se revisa	Frecuencia	Responsable	Disparador adicional
Vigencia de contenidos (cartilla, horarios, canales de contacto, novedades)	Mensual	Dueño del conocimiento	Cualquier cambio operativo real (alta o baja de un profesional o servicio, cambio de horario o canal)
Calidad del RAG (set de preguntas ciegas + precisión)	Mensual y después de cada re-ingesta	Revisor de calidad	Respuestas reportadas como incorrectas
Fidelidad del parseo (texto parseado contra documento original)	Después de cada re-parseo	Curador técnico	Cambio de tier o versión de LlamaParse
Consistencia entre documentos (datos repetidos en conflicto)	Trimestral	Dueño del conocimiento	Respuestas que muestran dos valores
Parámetros del RAG (Top-K, Min Score, chunking, prompt, modelo)	Trimestral (recalibrar el umbral con preguntas dentro y fuera de la base)	Curador técnico	Caída de precisión o fallas de recuperación recurrentes
Datos con vencimiento (certificados impositivos, novedades con fecha)	Antes de cada vencimiento	Dueño del conocimiento	Fecha de fin de vigencia (por ejemplo, certificado de IIBB hasta el 31/10/2026)
Seguridad y credenciales (API keys, tokens OAuth)	Trimestral	Responsable de seguridad	Credencial vencida o sospecha de exposición

3. Ciclo de vida del documento

1. **Alta:** el Dueño aprueba el documento → se anonimiza → se guarda el .docx en documentacion/ → python scripts/update_kb.py (parsea con LlamaParse y carga el markdown en n8n) → en n8n, ► **Ingerir KB (RAG)** (recrea la colección de Qdrant y la vuelve a llenar) → python scripts/verify_qdrant.py.
 2. **Actualización:** se cambia **siempre el documento fuente**, nunca el índice ni el markdown a mano. Se re-parsea solo ese documento y se re-ingiere. Como la ingesta recrea la colección, nunca conviven dos versiones del mismo contenido.
 3. **Baja o reemplazo:** se aplican los criterios de la sección 4. Se borra o reemplaza el .docx (y su .md) y se re-ingiere.
 4. **Trazabilidad:** documentos, markdown parseado, workflows exportados y scripts se versionan en Git. Cada respuesta del bot cita [Fuente: documento – sección].
-

4. Criterios de baja o reemplazo

Un documento **se da de baja o se reemplaza** cuando:

- **Quedó desactualizado:** un horario, profesional, canal o política que ya no rige. Un dato vencido indexado es peor que no tenerlo, porque induce respuestas falsas con apariencia de verdad (y con cita).
- **Venció su vigencia:** novedades con fecha, certificados o convenios. Si no se renuevan, se retiran en la fecha de fin.
- **Fue derogado o discontinuado:** un servicio que dejó de ofrecerse.
- **Existe una versión nueva:** se reemplaza el archivo; no conviven versiones.
- **Contradice a otra fuente** y el Dueño define cuál prevalece: la fuente perdedora se corrige o se retira.
- **Contiene datos personales o sensibles, o rompe la anonimización:** se corrige o se retira.

Toda baja o reemplazo la **aprueba el Dueño** y la **ejecuta el Curador**. Queda registrada en el historial de commits.

5. Hallazgos de esta entrega y acciones

Hallazgo	Evidencia	Acción
Dato en conflicto: camas de internación	160 (<i>Institucional — Filosofía</i>) contra 140 (<i>Residencias</i>). El bot informa ambos valores con su fuente.	El Dueño define el valor vigente y se corrige el documento erróneo. Revisión trimestral de cifras repetidas.
Anonimización incompleta	<i>Datos impositivos y Política de confidencialidad</i> nombran a "OMINT"; el bot atribuye esos datos a "la clínica".	Completar la anonimización o aclarar en el documento la relación entre la clínica y la razón social.
El parser alteró texto	LlamaParse (tier Agentic) cambió "Billinghurst" por "Billinghamurst" y "lodetinho" por "lodetinho" en 5 documentos.	Control automático después de cada parseo: comparar las palabras del .md contra el texto del .docx y revisar las diferencias antes de ingerir.
Datos en tablas con recuperación frágil	En la pregunta de IBBB Mendoza, la primera búsqueda devolvió 0 fragmentos sobre 0.60; recuperó al reformular.	Enriquecer los fragmentos de tabla con una frase descriptiva, o sumar búsqueda híbrida (palabras clave + vectores).
Tablas con varias normas en una celda	En la regresión, el bot respondió "19/12 y 30/99" para la percepción de IBBB Mendoza (correcto: 30/99); el validador no lo detecta porque el texto existe en la fuente.	Enriquecer los fragmentos de tabla con una frase que nombre cada columna; revisar las respuestas sobre tablas en el set ciego.
Datos con vencimiento	Certificados de no retención con vigencia hasta el 31/07/2026 y el 31/10/2026.	Agendar la revisión antes de cada vencimiento (sección 2).

6. Control de calidad

- **Set de preguntas ciegas:** al menos 5, con al menos una cuya respuesta esté fuera de la base y una basada en una tabla. Se renuevan las preguntas en cada corrida, para no "entrenar al examen", y se registran la precisión, las alucinaciones, la fidelidad de la cita y las fallas de recuperación.
- **Umbral de aceptación:** $\geq 80\%$ de precisión y 0 alucinaciones. Por debajo, se abre una acción correctiva antes de dar la base por "sana". Último resultado: 5/5 y 0 alucinaciones (pieza 4).
- **Recalibración del Min Score:** si cambia el modelo de embeddings o el chunking, se repite la calibración (scores de preguntas dentro y fuera de la base) antes de fijar el umbral.
- **Validador de salida:** cada respuesta del RAG queda marcada como aprobada, rechazada o no disponible, con el motivo. En cada revisión mensual se leen los rechazos: un rechazo repetido sobre el mismo tema indica un documento faltante, un fragmento mal cortado o una regla del prompt que hay que ajustar. El validador controla respaldo, no interpretación (ver pieza 4), así que no reemplaza al set de preguntas ciegas.
- **Herramienta de auditoría:** `python scripts/ver_ejecuciones.py` muestra, para las últimas consultas, la intención detectada, la respuesta enviada, el resultado del validador (y la respuesta bloqueada, si la hubo), las búsquedas que hizo el agente y los scores obtenidos.

7. Infraestructura y riesgos operativos

- **Vector store persistente:** Qdrant en Docker con volumen propio, así que la base sobrevive a reinicios. Solo se re-ingiere cuando cambia la documentación.
- **Credenciales con vencimiento:** durante esta entrega **venció el token OAuth de Gmail**, y la rama de log y respuesta por email falló hasta reconectarlo. Se incluye en la revisión trimestral de credenciales, y la

alerta es cualquier ejecución en error.

- **Sub-workflows publicados:** en n8n 2.x, la herramienta RAG y los workers solo se pueden llamar si están **publicados**. Después de editarlos, hay que volver a publicar.
 - **URL de webhooks:** WEBHOOK_URL tiene que apuntar a una URL viva. Un túnel temporal caído deja sin funcionar el chat y los webhooks.
 - **Costo de parseo:** el tier Agentic consume unos 400 créditos por re-parseo completo (plan gratis: 10.000). Se re-parsea solo lo que cambió (parse_kb.py sin --force).
 - **Dependencia de proveedores:** LlamaCloud, Cohere y Anthropic. Ante una caída, el bot sigue respondiendo con la base ya indexada (Qdrant es local); solo se frena la re-ingesta si falla LlamaParse o Cohere.
-

8. Seguridad y privacidad

- La base contiene **solo información pública institucional**: no se ingieren datos de pacientes.
 - Las API keys (n8n, LlamaCloud) viven en scripts/.env, fuera de Git. Las de Cohere y Anthropic, como credenciales cifradas de n8n.
 - La anonimización de la marca se verifica en cada alta (ver hallazgo "OMINT").
-

Resumen ejecutivo

La base se revisa **mensualmente** (vigencia y calidad, con preguntas ciegas), **después de cada re-parseo** (fidelidad del texto) y **trimestralmente** (consistencia, parámetros del RAG y credenciales). El **Dueño del conocimiento** aprueba altas, bajas y reemplazos, y el **Curador técnico** los ejecuta re-parseando y re-ingiriendo, siempre desde el documento fuente. Un documento se **retira o reemplaza** cuando queda desactualizado, vence, se deroga, aparece una versión nueva, contradice a otra fuente o rompe la privacidad o la anonimización. La calidad se exige en **≥ 80 % de precisión y 0 alucinaciones**, y la trazabilidad la dan la cita de fuente en cada respuesta y el versionado en Git.