1. Relevamiento del proceso y framework de priorización

Industria: salud ambulatoria privada: Clínica LoDeTincho (nombre anonimizado), con consultorios, diagnóstico por imágenes y guardia. **Proceso:** la **Central de Turnos** (sacar, modificar, consultar y confirmar turnos) y las consultas informativas (especialidades, profesionales, horarios, estudios, coberturas).

Problema operativo. La demanda entra por teléfono, email y mensajería y la atienden personas que repiten todo el día las mismas tareas. En los picos el teléfono se satura, fuera de horario nadie responde y los errores de carga (datos incompletos, turnos duplicados) se descubren cuando el paciente llega.

Por qué agéntico. Los pedidos llegan en lenguaje natural ("pasame el de mañana para el jueves a la tarde"), mezclan intenciones y dependen del contexto del paciente: un flujo con IF fijos no los interpreta; un sistema de especialistas acotados, bajo reglas de negocio y con un humano para lo delicado, sí.

Framework de priorización del asesor (1 = bajo, 5 = alto)

Proceso candidato	Impacto	Viabilidad no-code	Adopción	Total	Decisión
Gestión de turnos (sacar, modificar, consultar, confirmar)	5	5	4	**14**	**Prioridad 1**
Consultas informativas con base documental (RAG)	4	5	4	**13**	**Prioridad 1**
Recordatorios previos al turno	3	4	5	12	Prioridad 2
Triaje de urgencias médicas	5	2	2	9	Solo detectar y derivar a humano
Facturación, reintegros y coberturas	3	2	3	8	No automatizar: escalar

Baseline: punto de partida manual

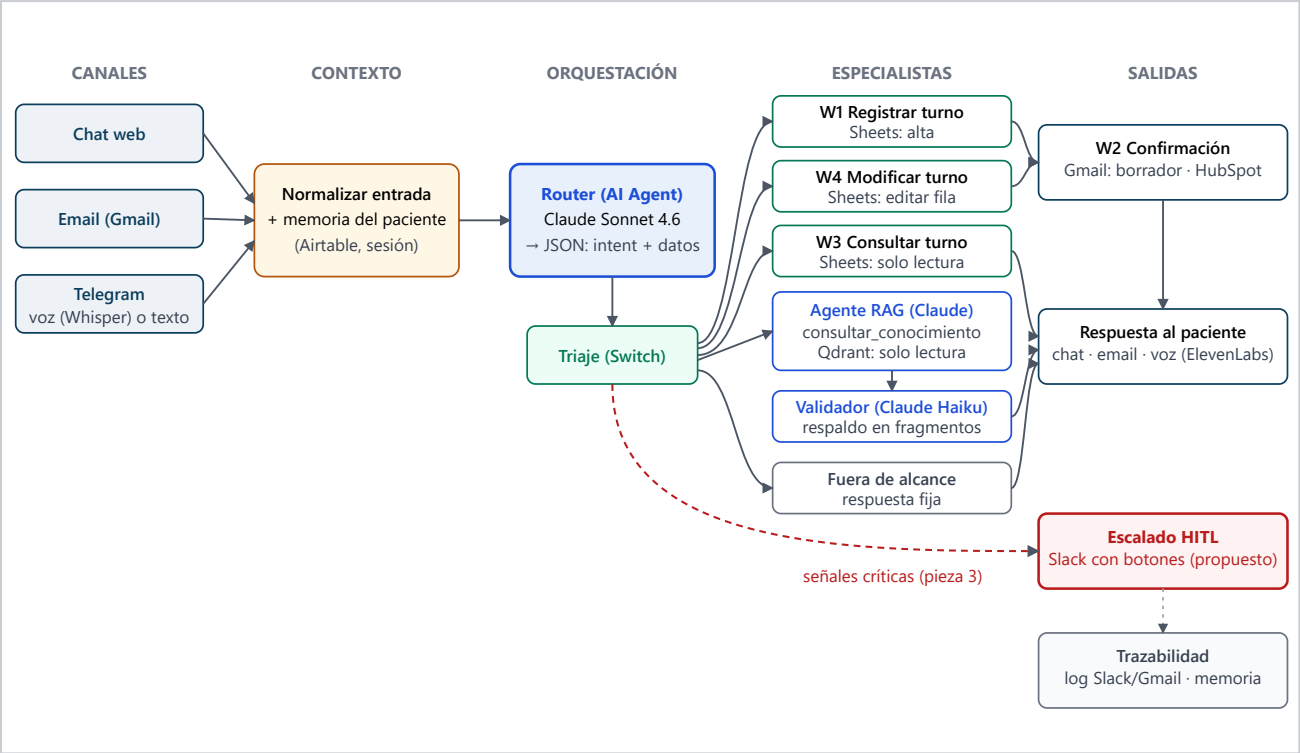
> **Supuestos** razonables para una clínica ambulatoria mediana, no datos reales: sirven para medir la mejora y se validan en el piloto (página 3).

Tarea manual	Quién la hace	Volumen diario	Tiempo por gestión	Min/día
Sacar un turno nuevo	Administrativas de la Central de Turnos	70	4 min	280
Modificar o cancelar un turno	Ídem	38	3 min	114
Consulta informativa	Ídem	72	2,5 min	180
Confirmación o recordatorio	Ídem	70	1 min	70
Total	**3 administrativas, de 8 a 20 h**	**250**		**644 (≈ 10,7 h)**

Por mes (22 días hábiles): ≈ **236 h** de trabajo repetitivo. **Costo** (supuesto: $ 10.000 por hora): ≈ **$ 2.360.000 por mes**. **Calidad** (supuestos): 5 % de turnos con datos incompletos o duplicados, 6 minutos de espera en picos y 20 % de contactos fuera de horario sin respuesta hasta el día siguiente.

2. Arquitectura multi-agente y mapa de permisos

Un **Router** clasifica cada pedido y un **triaje determinista** (Switch) lo deriva a especialistas acotados; los que escriben datos son workers sin LLM y el único que redacta texto libre (Agente RAG) pasa por un validador.



Rol	Misión	System Prompt constitutivo (extracto)	Herramientas	Entrega (JSON → a quién)
Router (Claude Sonnet 4.6)	Entender el pedido; no responde	"Taxonomía CERRADA: CREAR, MODIFICAR, CONSULTAR, INFO, FUERA_DE_ALCANCE. No inventes datos."	Memoria (Airtable + sesión)	`{intent, nombre, motivo, fecha, hora, email}` → Switch
W1 / W4 Registrar y modificar (sin LLM)	Alta o reprogramación de un turno validado	Reglas deterministas	Sheets: alta / editar fila	`{ok, id_turno, estado}` → W2
W3 Consultar (sin LLM)	Listar los turnos de la persona	—	Sheets: lectura	`{mensaje, turnos[]}` → respuesta
W2 Confirmación (sin LLM)	Confirmación en lenguaje claro	Plantilla fija	—	`{mensaje}` → HubSpot y Gmail (borrador)
Agente RAG (Claude Sonnet 4.6)	Responder con la base documental	"Usá EXCLUSIVAMENTE los fragmentos… Regla 'No sé'… Citá la fuente… Voz: máx. 200 caracteres."	Qdrant: lectura (Top-K 5, Min Score 0,60)	`{respuesta, fragmentos}` → Validador
Validador (Claude Haiku 4.5)	Auditar cada respuesta del RAG	"Todo dato concreto debe estar en los fragmentos; cita obligatoria."	—	`{aprobado, motivo}` → respuesta o texto seguro

Context Engineering: el Router recibe el mensaje, el estado del caso, el resumen y los datos clave del paciente y el canal; los workers, solo el JSON del contrato; el Agente RAG, la pregunta, la memoria (solo para personalizar) y los fragmentos **de ese turno**; el validador, pregunta, respuesta y fragmentos.

Conector	Acceso (mínimo privilegio)	Ajuste propuesto
Sheets `Agenda_Turnos`	W1 alta · W4 editar fila · W3 y Manager lectura	Cuenta de servicio limitada a la planilla; W3 con credencial de solo lectura
Airtable `Memoria`	Lectura y upsert solo en su tabla	Token con *scope* a una tabla, sin borrado
Qdrant	Herramienta RAG: solo búsqueda; escritura solo en la ingesta manual	Claves separadas de lectura y escritura
Gmail	Borradores y respuesta en el mismo hilo; log interno	Nunca un correo nuevo al paciente sin revisión
HubSpot · Slack	Contactos (buscar, crear, actualizar) · publicar en `#soporte` y aprobar por botón	Sin deals ni borrado · bot limitado al canal
Telegram · Whisper · ElevenLabs	Responder al mismo `chat_id` · transcribir · sintetizar	Límite de gasto mensual

3. Propuesta de valor y semáforo de riesgo (HITL)

Propuesta de valor. La Central de Turnos atiende las 24 horas, por el canal que el paciente ya usa (chat, email o un audio de Telegram), y el equipo administrativo deja de repetir tareas para ocuparse de los casos que necesitan una persona. Las preguntas frecuentes se contestan con la información oficial de la clínica, citando la fuente, y todo lo sensible (una urgencia, un reclamo, un tema de dinero) llega a un humano con el caso ya resumido.

KPIs (definidos antes de implementar; piloto de 4 semanas)

KPI	Línea de base (supuesta)	Meta del piloto
Tasa de resolución autónoma (gestiones sin intervención humana)	0 %	≥ 60 %
Horas administrativas liberadas	0 h	≥ 120 h por mes (≈ $ 1.200.000)
Respuestas informativas correctas (muestra auditada)	—	≥ 95 %
Escalados correctos ante señales críticas	—	100 %
Turnos con datos incompletos o duplicados	5 %	< 1 %
Tiempo de respuesta	6 min de espera en picos	< 15 s texto · < 20 s voz
Contactos fuera de horario sin respuesta	20 %	0 %

Semáforo operativo de riesgo

Nivel	Acciones	Autonomía
🟢 Verde	Logs y memoria; consultas informativas validadas; consultar turnos propios; alta de turno con datos completos; actualizar contacto; avisos fijos	**100 % autónomas**
🟡 Amarillo	Reprogramar o cancelar un turno; confirmación por email (queda como **borrador**); respuesta rechazada por el validador	Autónomas, registradas y **revisadas en el día**
🔴 Rojo	**Urgencia médica** ("dolor en el pecho", "no puedo respirar"); **reclamos o amenazas legales**; **dinero** (reintegros, cobros, coberturas); pedidos de **historia clínica** o datos de terceros; más de 2 cancelaciones en 30 días; 2 fallas de comprensión seguidas	**Congelamiento + supervisión humana obligatoria**

En rojo, el bot no resuelve: responde una frase fija ("Tu consulta la tiene que ver una persona del equipo; ya le avisé") y, ante una urgencia, indica de inmediato la **guardia 24 h**.

Protocolo de escalado forzado (Slack con botones)

1. **Detección:** un triaje previo al Router busca las señales rojas y el Router marca `riesgo: "alto"` cuando las infiere; cualquiera de los dos escala.
2. **Congelamiento:** el flujo se detiene en **Slack › Send and Wait for Response** a `#soporte`, con el resumen del caso, la señal y los últimos 3 mensajes.
3. **Botones: Tomar el caso** (el bot deja de responder) · **Responder con plantilla** · **Descartar** (falso positivo, queda registrado).
4. **Sin respuesta en 15 min:** se reenvía a coordinación por email; fuera de horario, el paciente recibe el teléfono de la guardia.
5. **Trazabilidad:** cada escalado queda en la memoria del paciente y en el log, para auditar sesgos y falsos positivos.

4. Scorecards y versión de portafolio

Los agentes razonan con rúbricas fijas: la misma entrada da siempre la misma decisión y cada decisión cita su evidencia.

Scorecard A — Validación de respuestas informativas (implementada)

La aplica el **Validador** (Claude Haiku) a cada respuesta del Agente RAG. Evidencia: **los fragmentos de la base documental recuperados en ese mismo turno**.

Criterio	Pregunta	Si falla
1. Respaldo de cada dato	¿Cada dato concreto (teléfonos, mails, profesionales, horarios, precios, cifras, direcciones, servicios) está en los fragmentos? Saludos y la sugerencia de llamar a la Central no cuentan como datos	**Rechazo** → respuesta segura: "No cuento con ese dato en la documentación de la clínica..."
2. Cita de fuente	Si usa datos de los fragmentos, ¿incluye al menos un `[Fuente: …]`?	Rechazo
3. Regla "No sé"	Si dice que no tiene el dato, ¿se abstiene de agregar datos ausentes?	Rechazo
Excepción	Un saludo sin datos de la clínica se aprueba aunque no haya fragmentos	—

Salida: `{aprobado, motivo}`. En el M5: 5 de 5 respuestas correctas en validación ciega y 0 falsos rechazos del validador.

Scorecard B — Prioridad y ruta de cada pedido (diseño)

La aplica el triaje (reglas en un nodo Code) con los datos que extrae el Router. Puntaje de 0 a 100.

Criterio	Peso	Cómo se puntúa	Evidencia
Señal clínica de alarma	40 %	40 si aparece una palabra o patrón de la lista de urgencias	Texto del mensaje o transcripción
Dinero o aspecto legal	25 %	25 si menciona reintegro, cobro, cobertura, abogado o denuncia	Texto del mensaje
Historial del paciente	20 %	20 si tiene 2 o más cancelaciones en 30 días o un caso "En Revisión"	Planilla de turnos y memoria
Confianza del entendimiento	15 %	15 si faltan datos tras 2 intentos o el audio fue ilegible 2 veces	Contrato de datos

Ruta: 0–14 → 🟢 autónomo · 15–39 → 🟡 autónomo con revisión en el día · 40 o más → 🔴 escalado a Slack. Una señal clínica suma 40 por sí sola: **una urgencia siempre va a un humano**.

Versión de portafolio (anonimizada)

Asistente de turnos multicanal con IA para una clínica ambulatoria. Diseño y construcción en n8n, sin código propio, de un sistema multi-agente que atiende la central de turnos por chat, email y notas de voz. Un agente clasificador entiende el pedido; especialistas acotados registran, modifican y consultan turnos; un agente de conocimiento responde con la documentación oficial y un segundo modelo audita cada respuesta antes de enviarla. Incluye memoria del paciente, respuesta por voz breve, protección de datos (los audios no se guardan) y un semáforo de riesgo que deriva urgencias, reclamos y temas de dinero a una persona. **Resultados esperados del piloto:** 60 % de resolución autónoma, más de 120 horas mensuales liberadas y atención las 24 horas. *Stack:* n8n, Claude, Qdrant, Whisper, ElevenLabs, Google Sheets, Airtable, HubSpot, Gmail, Slack y Telegram.