1. Relevamiento del proceso y framework de priorización

Industria: salud ambulatoria privada: Clínica LoDeTincho (nombre anonimizado), con consultorios, diagnóstico por imágenes y guardia. **Proceso:** la **Central de Turnos** (sacar, modificar, consultar y confirmar turnos) y las consultas informativas (especialidades, profesionales, horarios, estudios, coberturas).

Problema operativo. La demanda entra por teléfono, email y mensajería y la atienden personas que repiten todo el día las mismas tareas. En los picos el teléfono se satura, fuera de horario nadie responde y los errores de carga (datos incompletos, turnos duplicados) se descubren cuando el paciente llega.

Por qué agéntico. Los pedidos llegan en lenguaje natural ("pasame el de mañana para el jueves a la tarde"), mezclan intenciones y dependen del contexto del paciente: un flujo con IF fijos no los interpreta; un sistema de especialistas acotados, bajo reglas de negocio y con un humano para lo delicado, sí.

Framework de priorización del asesor (1 = bajo, 5 = alto; máximo 25)

En **accesos regulados**, 5 = poco dato regulado en juego; 1 = alto riesgo regulatorio (los datos de salud son *datos sensibles*, Ley 25.326, y la historia clínica tiene régimen propio, Ley 26.529).

Proceso	Operación	Ingresos	Viabilidad no-code	Accesos regulados	Adopción	Total	Fundamento y decisión
Gestión de turnos	5	4	5	4	4	**22**	Grueso del volumen; cada turno es facturable y ya no se pierden los pedidos fuera de horario; ya funciona en n8n; solo datos personales y motivo. **Prioridad 1**
Consultas informativas (RAG)	4	3	5	5	4	**21**	~40 % de los contactos; convierte consultas en turnos; información pública, sin datos del paciente. **Prioridad 1**
Recordatorios previos al turno	3	4	4	4	5	20	El ausentismo es un turno no facturado; no exige acción del paciente. Prioridad 2
Facturación, reintegros, coberturas	3	4	2	2	3	14	Impacta en la caja, pero sin API y con datos financieros. **Escalar a humano**
Triaje de urgencias médicas	5	2	2	1	2	12	Riesgo clínico y legal máximo. **Solo detectar y derivar a humano**

Baseline: punto de partida manual

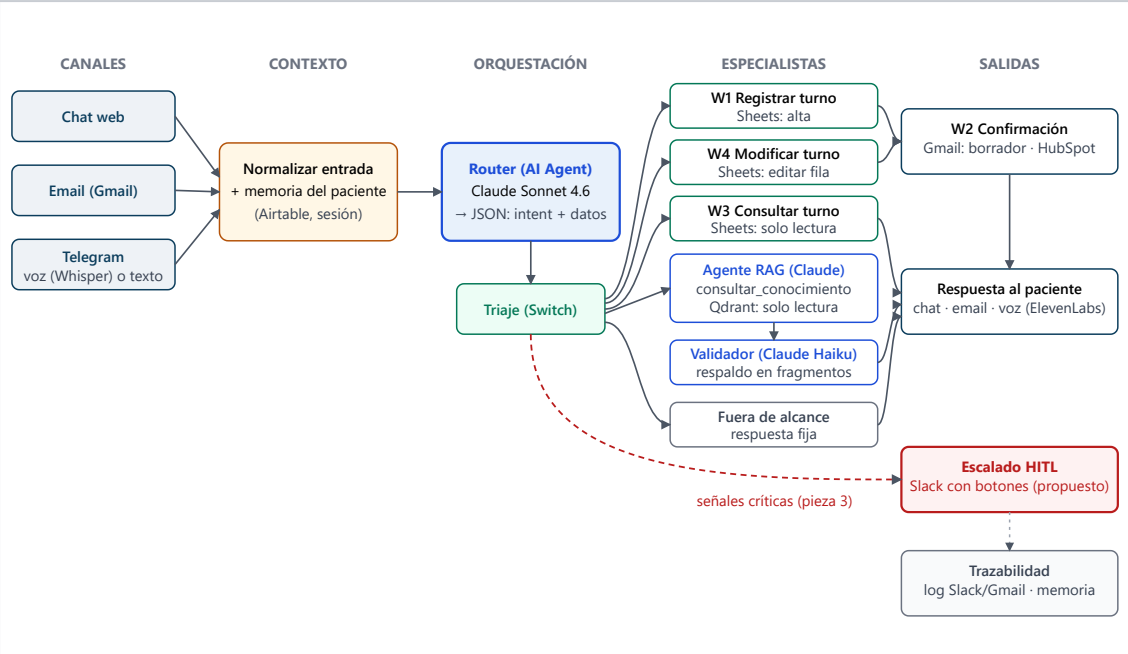
> **Supuestos** razonables para una clínica ambulatoria mediana, no datos reales: sirven para medir la mejora y se validan en el piloto (página 3).

Tarea manual	Quién la hace	Volumen diario	Tiempo por gestión	Min/día
Sacar un turno nuevo	Administrativas de la Central de Turnos	70	4 min	280
Modificar o cancelar un turno	Ídem	38	3 min	114
Consulta informativa	Ídem	72	2,5 min	180
Confirmación o recordatorio	Ídem	70	1 min	70
Total	**3 administrativas, de 8 a 20 h**	**250**		**644 (≈ 10,7 h)**

Por mes (22 días hábiles): ≈ **236 h** de trabajo repetitivo. **Costo** (supuesto: $ 10.000 por hora): ≈ **$ 2.360.000 por mes**. **Calidad** (supuestos): 5 % de turnos con datos incompletos o duplicados, 6 minutos de espera en picos y 20 % de contactos fuera de horario sin respuesta hasta el día siguiente.

2. Arquitectura multi-agente y mapa de permisos

Un **Router** clasifica y un **triaje** (Switch) deriva a especialistas acotados; los que escriben datos no usan LLM y el único que redacta texto libre (Agente RAG) pasa por un validador.



Rol	Misión	System Prompt constitutivo (extracto)	Herramientas	Entrega (JSON → a quién)
Router (Claude Sonnet 4.6)	Entender el pedido; no responde	"Taxonomía CERRADA: CREAR, MODIFICAR, CONSULTAR, INFO, FUERA_DE_ALCANCE. No inventes datos."	Memoria (Airtable + sesión)	`{intent, nombre, motivo, fecha, hora, email}` → Switch
W1 / W4 Registrar y modificar (sin LLM)	Alta o reprogramación de un turno validado	Reglas deterministas	Sheets: alta / editar fila	`{ok, id_turno, estado}` → W2
W3 Consultar (sin LLM)	Listar los turnos de la persona	—	Sheets: lectura	`{mensaje, turnos[]}` → respuesta
W2 Confirmación (sin LLM)	Confirmación en lenguaje claro	Plantilla fija	—	`{mensaje}` → HubSpot y Gmail (borrador)
Agente RAG (Claude Sonnet 4.6)	Responder con la base documental	"Usá EXCLUSIVAMENTE los fragmentos… Regla 'No sé'… Citá la fuente… Voz: máx. 200 caracteres."	Qdrant: lectura (Top-K 5, Min Score 0,60)	`{respuesta, fragmentos}` → Validador
Validador (Claude Haiku 4.5)	Auditar cada respuesta del RAG	"Todo dato concreto debe estar en los fragmentos; cita obligatoria."	—	`{aprobado, motivo}` → respuesta o texto seguro

Context Engineering: Router → mensaje, canal, estado, resumen y datos clave del paciente · workers → solo el JSON del contrato · Agente RAG → pregunta, memoria (solo para personalizar) y fragmentos **de ese turno** · validador → pregunta, respuesta y fragmentos.

Permisos por rol (mínimo privilegio). L = lectura · E = escritura · — = sin acceso.

Rol	Sheets Agenda	Airtable Memoria	Qdrant	Gmail	HubSpot	Slack	Telegram
Router (agente)	—	L	—	—	—	—	—
Manager (orquestación)	L	L/E	—	E	—	E	E
W1 Registrar	E	—	—	—	—	—	—
W4 Modificar	L/E	—	—	—	—	—	—
W3 Consultar	L	—	—	—	—	—	—
Confirmación (W2)	—	—	—	E	L/E	—	—
Agente RAG	—	L	L	—	—	—	—
Validador	—	—	—	—	—	—	—
Resumidor de memoria	—	E	—	—	—	—	—
Escalado HITL	—	L	—	E	—	L/E	—
Ingesta de la base	—	—	E	—	—	—	—

Alcances: Gmail solo borradores y respuestas en el hilo; Slack solo `#soporte`; Telegram solo al mismo chat; HubSpot solo contactos; Airtable solo la tabla del módulo. **Ajustes:** cuenta de servicio de Google limitada a la planilla; claves de Qdrant separadas de lectura y escritura; límite de gasto en OpenAI y ElevenLabs.

3. Propuesta de valor y semáforo de riesgo (HITL)

Propuesta de valor. La Central de Turnos atiende las 24 horas, por el canal que el paciente ya usa (chat, email o un audio de Telegram), y el equipo administrativo deja de repetir tareas para ocuparse de los casos que necesitan una persona. Las preguntas frecuentes se contestan con la información oficial de la clínica, citando la fuente, y todo lo sensible (una urgencia, un reclamo, un tema de dinero) llega a un humano con el caso ya resumido.

KPIs (definidos antes de implementar; piloto de 4 semanas)

KPI	Línea de base (supuesta)	Meta del piloto
Tasa de resolución autónoma (gestiones sin intervención humana)	0 %	≥ 60 %
Horas administrativas liberadas	0 h	≥ 120 h por mes (≈ $ 1.200.000)
Respuestas informativas correctas (muestra auditada)	—	≥ 95 %
Escalados correctos ante señales críticas	—	100 %
Turnos con datos incompletos o duplicados	5 %	< 1 %
Tiempo de respuesta	6 min de espera en picos	< 15 s texto · < 20 s voz
Contactos fuera de horario sin respuesta	20 %	0 %
Turnos sacados fuera de horario (ingresos)	0 %	≥ 10 % del total
Ausentismo (ingresos)	15 % (supuesto)	≤ 10 % con recordatorios

Semáforo operativo de riesgo

Nivel	Acciones	Autonomía
🟢 Verde	Logs y memoria; consultas informativas validadas; consultar turnos propios; alta de turno con datos completos; actualizar contacto; avisos fijos	**100 % autónomas**
🟡 Amarillo	Reprogramar o cancelar un turno; confirmación por email (queda como **borrador**); respuesta rechazada por el validador	**100 % autónomas, sin congelamiento**; auditoría humana diaria posterior
🔴 Rojo	**Urgencia médica** ("dolor en el pecho", "no puedo respirar"); **reclamos o amenazas legales**; **dinero** (reintegros, cobros, coberturas); pedidos de **historia clínica** o datos de terceros; **riesgo de abandono (churn)**: más de 2 cancelaciones en 30 días; 2 fallas de comprensión seguidas	**Congelamiento + supervisión humana obligatoria**

Frontera taxativa: solo el rojo congela y exige un humano. En rojo, el bot no resuelve: responde una frase fija ("Tu consulta la tiene que ver una persona del equipo; ya le avisé") y, ante una urgencia, indica de inmediato la **guardia 24 h**.

Protocolo de escalado forzado (Slack con botones)

1. **Detección:** nodos IF y Switch (sin código) previos al Router buscan las señales rojas y el Router marca `riesgo: "alto"` cuando las infiere; cualquiera de los dos escala.
2. **Congelamiento:** el flujo se detiene en **Slack › Send and Wait for Response** a `#soporte`, con el resumen del caso, la señal y los últimos 3 mensajes.
3. **Botones: Tomar el caso** (el bot deja de responder) · **Responder con plantilla** · **Descartar** (falso positivo, queda registrado).
4. **Sin respuesta en 15 min:** se reenvía a coordinación por email; fuera de horario, el paciente recibe el teléfono de la guardia.
5. **Trazabilidad:** cada escalado queda en la memoria del paciente y en el log, para auditar sesgos y falsos positivos.

4. Scorecards y versión de portafolio

Los agentes razonan con rúbricas fijas: la misma entrada da siempre la misma decisión y cada decisión cita su evidencia.

Scorecard A — Validación de respuestas informativas (implementada)

La aplica el **Validador** (Claude Haiku) a cada respuesta del Agente RAG. Evidencia: **los fragmentos de la base documental recuperados en ese mismo turno**.

Criterio	Pregunta	Si falla
1. Respaldo de cada dato	¿Cada dato concreto (teléfonos, mails, profesionales, horarios, precios, cifras, direcciones, servicios) está en los fragmentos? Saludos y la sugerencia de llamar a la Central no cuentan como datos	**Rechazo** → respuesta segura: "No cuento con ese dato en la documentación de la clínica…"
2. Cita de fuente	Si usa datos de los fragmentos, ¿incluye al menos un `[Fuente: …]`?	Rechazo
3. Regla "No sé"	Si dice que no tiene el dato, ¿se abstiene de agregar datos ausentes?	Rechazo
Excepción	Un saludo sin datos de la clínica se aprueba aunque no haya fragmentos	—

Salida: `{aprobado, motivo}`. En el M5: 5 de 5 respuestas correctas en validación ciega y 0 falsos rechazos del validador.

Scorecard B — Prioridad y ruta de cada pedido (diseño)

La aplica el triaje, armado con nodos **IF y Switch** (sin código), con los datos que extrae el Router. Puntaje de 0 a 100; cada criterio rojo alcanza solo el umbral de escalado (coincide con el semáforo).

Criterio	Peso	Cómo se puntúa	Evidencia
Señal clínica de alarma	35 %	35 si aparece una palabra o patrón de la lista de urgencias	Mensaje o transcripción
Dinero, legal o datos sensibles	25 %	25 si menciona reintegro, cobro, cobertura, abogado, denuncia, historia clínica o datos de terceros	Texto del mensaje
Riesgo de abandono (churn)	20 %	20 si tiene más de 2 cancelaciones en 30 días	Planilla de turnos y memoria
Confianza del entendimiento	20 %	10 con una falla de comprensión o audio ilegible; 20 con dos seguidas	Contrato de datos

Ruta: 0–9 → 🟢 autónomo · 10–19 → 🟡 autónomo, con auditoría diaria · 20 o más → 🔴 escalado a Slack. **Una urgencia, un tema de dinero o legal, un churn o dos fallas seguidas siempre llegan a un humano.**

Versión de portafolio (anonimizada)

Asistente de turnos multicanal con IA para una clínica ambulatoria. Diseño y construcción en n8n, sin código propio, de un sistema multi-agente que atiende la central de turnos por chat, email y notas de voz. Un agente clasificador entiende el pedido; especialistas acotados registran, modifican y consultan turnos; un agente de conocimiento responde con la documentación oficial y un segundo modelo audita cada respuesta antes de enviarla. Incluye memoria del paciente, respuesta por voz breve, protección de datos (los audios no se guardan) y un semáforo de riesgo que deriva urgencias, reclamos y temas de dinero a una persona. **Resultados esperados del piloto:** 60 % de resolución autónoma, más de 120 horas mensuales liberadas y atención las 24 horas. *Stack:* n8n, Claude, Qdrant, Whisper, ElevenLabs, Google Sheets, Airtable, HubSpot, Gmail, Slack y Telegram.