Pre-entrega Módulo 7
Diseño arquitectónico de un sistema agéntico vertical

Salud: Central de Turnos de una clínica

Proyecto integrador **AgendaBot** — AI Automation Avanzado (Coderhouse)

Julio Martín Waisburd

12/10/2026

Índice

1. Relevamiento del proceso y framework de priorización ..... pág. 2
2. Arquitectura del sistema multi-agente y mapa de permisos ..... pág. 4
3. Propuesta de valor y semáforo de riesgo (HITL) ..... pág. 7
4. Scorecards y versión de portafolio ..... pág. 9

1. Relevamiento del proceso y framework de priorización

Industria: salud ambulatoria privada. **Organización:** Clínica LoDeTincho (nombre anonimizado), con consultorios de varias especialidades, diagnóstico por imágenes y guardia. **Proceso:** la **Central de Turnos**: sacar, modificar, consultar y confirmar turnos, y responder consultas informativas (especialidades, profesionales, horarios, estudios, preparación, coberturas).

Problema operativo. La demanda entra por teléfono, email y mensajería, y la atienden personas que repiten todo el día las mismas tareas: buscar un hueco en la agenda, anotar los datos del paciente, confirmar por email y contestar preguntas cuya respuesta está en documentos internos. En los picos, el teléfono se satura; fuera de horario, nadie responde; y los errores de carga (datos incompletos, turnos duplicados) se detectan recién cuando el paciente llega.

Por qué una solución agéntica y no una automatización lineal. Los pedidos llegan en lenguaje natural ("pasame el de mañana para el jueves a la tarde"), mezclan intenciones y dependen del contexto del paciente. Un flujo con IF fijos no los interpreta; un agente con especialistas acotados sí, siempre que trabaje bajo reglas de negocio y con un humano para lo delicado.

Framework de priorización del asesor

Escala 1 (bajo) a 5 (alto). Los tres vectores pesan igual.

Proceso candidato	Impacto en la operación	Viabilidad técnica no-code	Adopción probable	Total	Decisión
Gestión de turnos (sacar, modificar, consultar, confirmar)	5 — es el grueso del volumen de la central	5 — ya funciona en n8n con Sheets	4 — el paciente ya pide turnos por WhatsApp/Telegram	**14**	**Prioridad 1**
Consultas informativas con base documental (RAG)	4 — ~40 % de los contactos	5 — RAG con validador funcionando	4 — respuestas con cita de fuente	**13**	**Prioridad 1**
Recordatorios y confirmación previa al turno	3 — reduce ausentismo	4 — disparo programado	5 — no requiere acción del paciente	12	Prioridad 2
Triaje de urgencias médicas	5	2 — riesgo clínico, requiere protocolo médico	2 — baja confianza del paciente	9	**Fuera de la autonomía**: solo detectar y derivar a humano
Facturación, reintegros y coberturas	3	2 — sistemas de facturación sin API	3	8	No automatizar; escalar a humano

Baseline: punto de partida manual

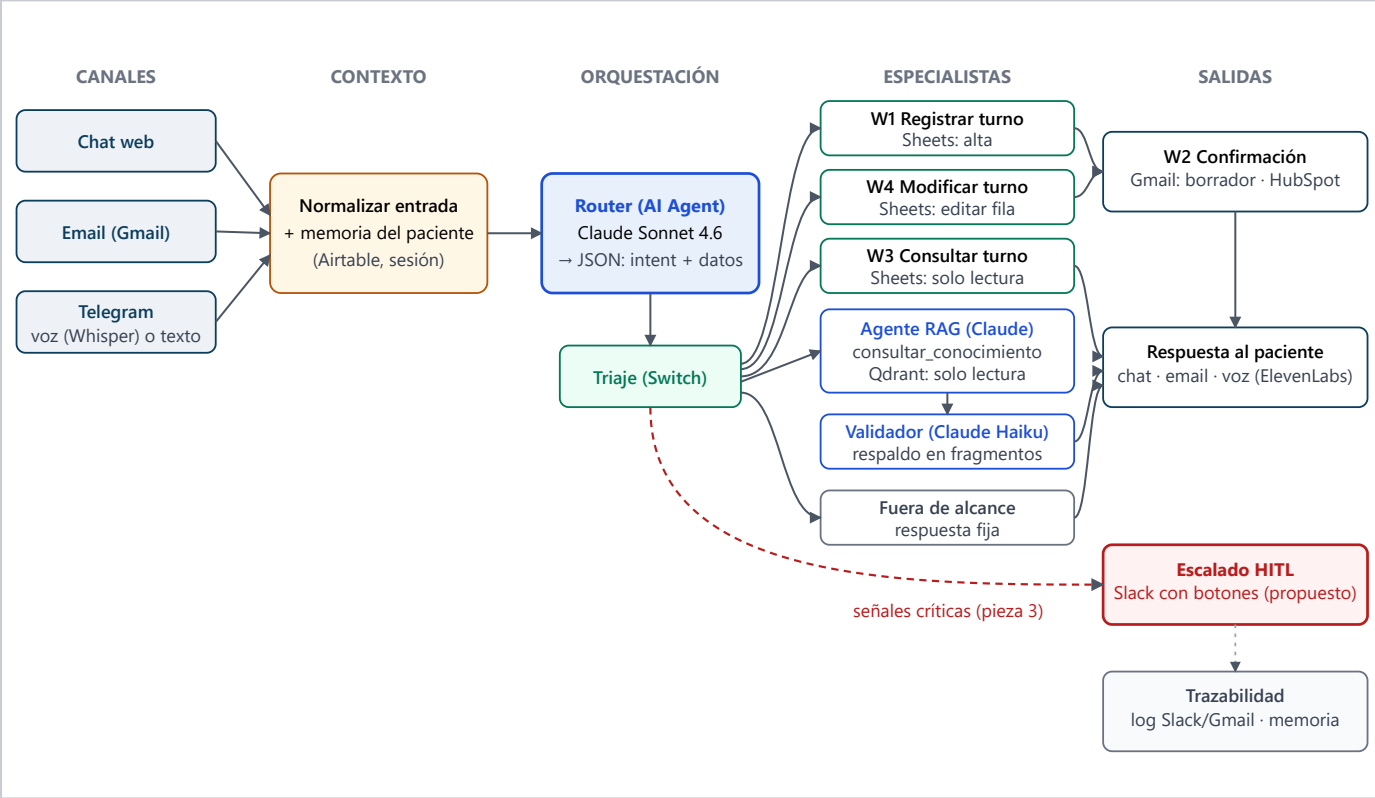
> **Supuestos.** Los números de esta sección no provienen de la clínica real: son supuestos razonables para una clínica ambulatoria mediana, declarados para poder medir la mejora. Se validan en el piloto (pieza 3, KPIs).

Tarea manual	Quién la hace hoy	Volumen diario (supuesto)	Tiempo por gestión (supuesto)	Minutos por día
Sacar un turno nuevo	Administrativas de la Central de Turnos	70	4 min	280
Modificar o cancelar un turno	Ídem	38	3 min	114
Consulta informativa (horarios, profesionales, estudios)	Ídem	72	2,5 min	180
Confirmación o recordatorio manual	Ídem	70	1 min	70
Total	**3 administrativas, de 8 a 20 h**	**250 contactos**		**644 min ≈ 10,7 h por día**

- **Horas por mes** (22 días hábiles): ≈ **236 h** de trabajo administrativo repetitivo.
- **Costo** (supuesto, a efectos de la muestra: $ 10.000 por hora administrativa): 236 h × $ 10.000 ≈ **$ 2.360.000 por mes** solo en estas tareas.
- **Calidad** (supuestos): 5 % de los turnos con datos incompletos o duplicados; espera telefónica promedio de 6 minutos en picos; 20 % de los contactos fuera de horario quedan sin respuesta hasta el día siguiente.

2. Arquitectura del sistema multi-agente y mapa de permisos

La coreografía es la de AgendaBot (construido del M1 al M6): un **Router** clasifica cada pedido y un **triaje determinista** (Switch) lo deriva a especialistas con alcance acotado. Ningún agente hace "todo"; los que escriben datos son workers sin LLM, y el único que redacta texto libre (Agente RAG) está controlado por un validador.



Línea continua: delegación. Línea roja: escalado a humano. Los especialistas devuelven JSON al Manager; ninguno se comunica directamente con otro.

Fichas de los agentes

Rol	Misión	System Prompt constitutivo (extracto)	Herramientas	Entrega (JSON → a quién)
Router (AI Agent, Claude Sonnet 4.6)	Entender el pedido y extraer datos; no responde al paciente	"Clasificá en una taxonomía CERRADA: CREAR_TURNO, MODIFICAR_TURNO, CONSULTAR_TURNO, INFO, FUERA_DE_ALCANCE... No calcules fechas; extraé solo números... No inventes datos."	Memoria de sesión; contexto de Airtable	`{intent, nombre, motivo, dia, mes, hora, *_ref, email}` → Contrato de datos → Switch
W1 Registrar turno (sin LLM)	Dar de alta un turno validado	— (regla determinista)	Sheets `Agenda_Turnos`: alta	`{ok, id_turno, fecha, hora}` → W2
W4 Modificar turno (sin LLM)	Reprogramar o cancelar el turno identificado	—	Sheets: actualizar la fila del turno	`{ok, id_turno, estado}` → W2
W3 Consultar turno (sin LLM)	Listar los turnos de la persona	—	Sheets: solo lectura	`{mensaje, turnos[]}` → respuesta
W2 Confirmación (sin LLM)	Armar la confirmación en lenguaje claro	Plantilla fija	—	`{mensaje}` → HubSpot (contacto) y Gmail (borrador)
Agente RAG (AI Agent, Claude Sonnet 4.6)	Responder consultas informativas con la base documental	"Usá EXCLUSIVAMENTE los fragmentos de consultar_conocimiento... Regla 'No sé'... Citá la fuente... Canal de voz: máximo 200 caracteres."	`consultar_conocimiento` (Qdrant, Top-K 5, Min Score 0,60); memoria del paciente	`{respuesta, fragmentos}` → Validador
Validador (Claude Haiku 4.5)	Auditar cada respuesta del RAG contra los fragmentos del turno	"Aprobá solo si cada dato concreto está respaldado por los fragmentos recuperados."	—	`{aprobado, motivo}` → si rechaza, sale una respuesta segura
Resumidor de memoria (Claude)	Consolidar la charla cada 5 mensajes	"Resumen analítico, no transcripción; datos clave."	Airtable `Memoria_M6`: upsert	`{resumen, datos_clave, estado}` → Airtable

Context Engineering: qué recibe cada sub-workflow

Destino	Recibe	No recibe (a propósito)
Router	Mensaje actual, estado del caso, resumen de la última charla, datos clave del paciente, canal	Agenda completa, base documental
Workers de turnos	Solo el JSON del contrato (nombre, motivo, fecha, hora, email, turno de referencia)	Historial de chat, memoria
Agente RAG	Pregunta, memoria del paciente (solo para personalizar) y los fragmentos recuperados **en ese turno**	Datos de turnos de otras personas
Validador	Pregunta, respuesta propuesta y fragmentos	Memoria, historial
Escalado HITL (propuesto)	Resumen del caso, señal crítica detectada, últimos 3 mensajes, contacto	Audios (se descartan, pieza 7 del M6)

Mapa de permisos (mínimo privilegio)

Conector	Quién lo usa	Acceso	Hoy	Ajuste propuesto
Google Sheets `Agenda_Turnos`	W1 / W4 / W3 / Manager	W1 **alta**, W4 **editar fila**, W3 y Manager **lectura**	Una credencial OAuth con acceso a todo el Drive	Cuenta de servicio con acceso solo a la planilla del módulo; W3 con credencial de solo lectura
Airtable `Memoria_Agente`	Manager	Lectura y upsert en **su** tabla (`Memoria_M6`)	Token con acceso a la base	Token con *scope* a una tabla y sin borrado
Qdrant `kb_lodetincho_m5`	Herramienta RAG	**Solo lectura** (búsqueda)	La escritura solo ocurre en "Ingerir KB"	Clave de solo lectura para la herramienta; la de escritura, solo para la ingesta manual
Gmail	Manager	**Borradores** y respuesta en el mismo hilo; log a una casilla interna	Envío posible	Mantener: al paciente nunca se le envía un correo nuevo sin revisión (borrador)
HubSpot	Manager	Buscar, crear y actualizar **contactos**	App token	*Scopes* solo de contactos (sin deals ni borrado)
Slack	Manager / HITL	Publicar en `#soporte`; aprobaciones por botón	Bot token	Bot limitado al canal de soporte
Telegram, OpenAI (Whisper), ElevenLabs	Capa de voz	Responder solo al mismo `chat_id`; transcribir; sintetizar	Tokens de API	Límite de gasto mensual en OpenAI y ElevenLabs

3. Propuesta de valor y semáforo de riesgo (HITL)

Propuesta de valor

La Central de Turnos atiende las 24 horas, por el canal que el paciente ya usa, y el equipo administrativo deja de repetir tareas para ocuparse de los casos que necesitan una persona. El paciente saca, cambia o consulta su turno por chat, email o un audio de Telegram, y recibe la respuesta en segundos; las preguntas frecuentes se contestan con la información oficial de la clínica, citando la fuente; y todo lo sensible (una urgencia, un reclamo, un tema de dinero) llega a un humano con el caso ya resumido.

KPIs (definidos antes de implementar)

Línea de base: el baseline supuesto de la pieza 1. Se miden durante un piloto de 4 semanas con los logs de n8n y la planilla de turnos.

KPI	Cómo se mide	Línea de base (supuesta)	Meta del piloto
Tasa de resolución autónoma	Gestiones cerradas sin intervención humana / total	0 %	≥ 60 %
Horas administrativas liberadas	(gestiones autónomas × minutos del baseline) / 60	0 h	≥ 120 h por mes
Respuestas informativas correctas	Muestra semanal auditada contra la base documental	—	≥ 95 % (en el M5: 5 de 5 en validación ciega)
Escalados correctos	Casos con señal crítica que llegaron a un humano / casos con señal crítica	—	100 %
Turnos con datos incompletos o duplicados	Revisión de la planilla	5 %	< 1 %
Tiempo de respuesta	Del mensaje a la respuesta	6 min de espera en picos	< 15 s texto; < 20 s voz
Contactos fuera de horario sin respuesta	Mensajes fuera de 8–20 h sin contestar	20 %	0 %

Semáforo operativo de riesgo

Nivel	Acciones	Autonomía
🟢 **Verde**	Registrar logs y memoria; responder consultas informativas validadas; consultar los turnos propios; dar de alta un turno con datos completos; actualizar un contacto en HubSpot; avisos fijos (fuera de alcance, audio ilegible)	**100 % autónomas**
🟡 **Amarillo**	Reprogramar o cancelar un turno; enviar una confirmación por email (queda como **borrador** en Gmail); respuesta que el validador rechazó	**Autónomas con control**: se ejecutan, quedan registradas y un humano las revisa en el día
🔴 **Rojo**	Señales de **urgencia médica** ("dolor en el pecho", "no puedo respirar"); **reclamos o amenazas legales**; **dinero**: reintegros, cobros, diferencias de cobertura; pedidos de **historia clínica** o datos de otra persona; **cancelación** de más de 2 turnos del mismo paciente en 30 días (riesgo de abandono); 2 fallas de comprensión seguidas	**Congelamiento + supervisión humana obligatoria**

En rojo, el bot no resuelve: responde una frase fija ("Tu consulta la tiene que ver una persona del equipo; ya le avisé") y, ante una urgencia médica, indica de inmediato la **guardia 24 h** sin esperar a nadie.

Protocolo de escalado forzado (Slack con botones)

1. **Detección:** antes del Router, un nodo de triaje busca las señales rojas (lista de palabras y patrones) y el Router marca `riesgo: "alto"` cuando las infiere. Cualquiera de los dos dispara el escalado; no se le deja al modelo la decisión de **no** escalar.
2. **Congelamiento:** el flujo se detiene en un nodo **Slack › Send and Wait for Response** dirigido a `#soporte`, con el resumen del caso, la señal detectada y los últimos 3 mensajes.
3. **Botones: Tomar el caso** (una persona contacta al paciente y el bot no responde más en esa conversación), **Responder con plantilla** (el bot envía el texto aprobado) o **Descartar** (falso positivo; queda registrado para mejorar la detección).
4. **Tiempo de espera:** si nadie responde en 15 minutos en horario laboral, se reenvía a la coordinación por email; fuera de horario, el paciente recibe el teléfono de la guardia.
5. **Trazabilidad:** cada escalado y su decisión quedan en la memoria del paciente (Airtable) y en el log, para auditar sesgos y falsos positivos cada semana.

Estado: el log a Slack, el borrador de Gmail y el validador ya funcionan en el M6; el nodo de aprobación con botones es la incorporación propuesta en este diseño.

4. Scorecards y versión de portafolio

Los agentes razonan con dos rúbricas fijas y públicas para el equipo, de modo que la misma entrada dé siempre la misma decisión y cada decisión cite su evidencia.

Scorecard A — Validación de respuestas informativas (implementada)

La usa el **Validador** (Claude Haiku) sobre cada respuesta del Agente RAG. La evidencia son **los fragmentos de la base documental recuperados en ese mismo turno**; nada de lo que dice la respuesta puede salir de otro lado.

Criterio	Pregunta que se hace	Evidencia exigida	Si falla
1. Respaldo de cada dato	¿Cada dato concreto sobre la clínica (teléfonos, mails, profesionales, horarios, precios, cifras, direcciones, servicios) está en los fragmentos? Saludos, el nombre del paciente y la sugerencia de llamar a la Central de Turnos no cuentan como datos	Texto de los fragmentos	**Rechazo** → sale la respuesta segura: "No cuento con ese dato en la documentación de la clínica..."
2. Cita de fuente	Si la respuesta usa datos de los fragmentos, ¿incluye al menos una cita `[Fuente: …]`?	La cita	Rechazo
3. Regla "No sé"	Si la respuesta dice que no tiene el dato, ¿se abstiene de agregar datos ausentes de los fragmentos?	Fragmentos	Rechazo
Excepción	Un saludo o una respuesta sin datos de la clínica se aprueba aunque no haya fragmentos	—	—

Los fragmentos que recibe el validador son solo los recuperados **en ese turno**: si el agente no consultó la base, el validador recibe "(el asistente no consultó la base documental)" y cualquier dato concreto queda sin respaldo.

Salida: `{aprobado: true|false, motivo}`. Resultado en el M5: 5 de 5 respuestas correctas en la validación ciega y 0 falsos rechazos del validador en la regresión.

Scorecard B — Prioridad y ruta de cada pedido (diseño)

La aplica el **triaje** (reglas en un nodo Code) con los datos que extrae el Router. Puntaje de 0 a 100; la suma decide la ruta.

Criterio	Peso	Cómo se puntúa	Evidencia
Señal clínica de alarma	40 %	40 si hay una palabra o patrón de la lista de urgencias; 0 si no	Texto del mensaje (y transcripción si fue audio)
Dinero o aspecto legal	25 %	25 si menciona reintegro, cobro, cobertura, abogado o denuncia	Texto del mensaje
Historial del paciente	20 %	20 si tiene 2 o más cancelaciones en 30 días o un caso "En Revisión"	Planilla de turnos y memoria (Airtable)
Confianza del entendimiento	15 %	15 si faltan datos obligatorios tras 2 intentos o el audio fue ilegible 2 veces	Contrato de datos y evaluación de la transcripción

Puntaje	Ruta
0–14	🟢 Autónomo (flujo normal)
15–39	🟡 Autónomo con control: se registra y se revisa en el día
40 o más	🔴 Escalado forzado a Slack (pieza 3)

Cualquier señal clínica de alarma suma 40 por sí sola: **una urgencia siempre va a un humano**, sin importar el resto.

Versión de portafolio (anonimizada)

Asistente de turnos multicanal con IA para una clínica ambulatoria. Diseño y construcción, en n8n y sin código propio, de un sistema multi-agente que atiende la central de turnos por chat, email y notas de voz. Un agente clasificador entiende el pedido; especialistas acotados registran, modifican y consultan turnos en la agenda; un agente de conocimiento responde con la documentación oficial y un segundo modelo audita cada respuesta antes de enviarla. Incluye memoria del paciente, respuesta por voz de menos de 200 caracteres, protección de datos (los audios no se guardan) y un semáforo de riesgo que deriva urgencias, reclamos y temas de dinero a una persona. **Resultados esperados del piloto:** 60 % de resolución autónoma, más de 120 horas mensuales liberadas y atención las 24 horas. *Stack:* n8n, Claude (Anthropic), Qdrant, Whisper, ElevenLabs, Google Sheets, Airtable, HubSpot, Gmail, Slack y Telegram.