Pre-entrega Módulo 7
Diseño arquitectónico de un sistema agéntico vertical

Salud: Central de Turnos de una clínica

Proyecto integrador **AgendaBot** — AI Automation Avanzado (Coderhouse)

Julio Martín Waisburd

12/10/2026

Índice

1. Relevamiento del proceso y framework de priorización ..... pág. 2
2. Arquitectura del sistema multi-agente y mapa de permisos ..... pág. 4
3. Propuesta de valor y semáforo de riesgo (HITL) ..... pág. 7
4. Scorecards y versión de portafolio ..... pág. 9

1. Relevamiento del proceso y framework de priorización

Industria: salud ambulatoria privada. **Organización:** Clínica LoDeTincho (nombre anonimizado), con consultorios de varias especialidades, diagnóstico por imágenes y guardia. **Proceso:** la **Central de Turnos**: sacar, modificar, consultar y confirmar turnos, y responder consultas informativas (especialidades, profesionales, horarios, estudios, preparación, coberturas).

Problema operativo. La demanda entra por teléfono, email y mensajería, y la atienden personas que repiten todo el día las mismas tareas: buscar un hueco en la agenda, anotar los datos del paciente, confirmar por email y contestar preguntas cuya respuesta está en documentos internos. En los picos, el teléfono se satura; fuera de horario, nadie responde; y los errores de carga (datos incompletos, turnos duplicados) se detectan recién cuando el paciente llega.

Por qué una solución agéntica y no una automatización lineal. Los pedidos llegan en lenguaje natural ("pasame el de mañana para el jueves a la tarde"), mezclan intenciones y dependen del contexto del paciente. Un flujo con IF fijos no los interpreta; un agente con especialistas acotados sí, siempre que trabaje bajo reglas de negocio y con un humano para lo delicado.

Framework de priorización del asesor

Escala 1 a 5; todos los vectores pesan igual (máximo 25). En **accesos regulados**, 5 significa poco dato regulado en juego y 1, datos o decisiones de alto riesgo regulatorio: en salud, los datos de salud son **datos sensibles** (Ley 25.326 de Protección de Datos Personales) y la historia clínica tiene un régimen propio (Ley 26.529 de Derechos del Paciente).

Proceso candidato	Impacto en la operación	Impacto en ingresos	Viabilidad no-code	Accesos regulados	Adopción probable	Total	Decisión
Gestión de turnos (sacar, modificar, consultar, confirmar)	5 — es el grueso del volumen de la central	4 — cada turno es una prestación facturable; se dejan de perder los pedidos fuera de horario	5 — ya funciona en n8n con Sheets	4 — nombre, contacto y motivo: datos personales, con el motivo como dato de salud mínimo	4 — el paciente ya escribe por mensajería	**22**	**Prioridad 1**
Consultas informativas con base documental (RAG)	4 — ~40 % de los contactos	3 — convierte consultas en turnos	5 — RAG con validador funcionando	5 — información pública de la clínica, sin datos del paciente	4 — respuestas con cita de fuente	**21**	**Prioridad 1**
Recordatorios previos al turno	3 — reduce llamadas de confirmación	4 — el ausentismo es un turno no facturado	4 — disparo programado	4 — solo datos del turno	5 — no requiere acción del paciente	20	Prioridad 2
Facturación, reintegros y coberturas	3	4 — impacta directo en la caja	2 — sistemas de facturación sin API	2 — datos de cobertura y financieros	3	14	No automatizar; escalar a humano
Triaje de urgencias médicas	5	2	2 — requiere protocolo médico	1 — riesgo clínico y legal máximo	2 — baja confianza del paciente	12	**Fuera de la autonomía**: solo detectar y derivar a humano

Baseline: punto de partida manual

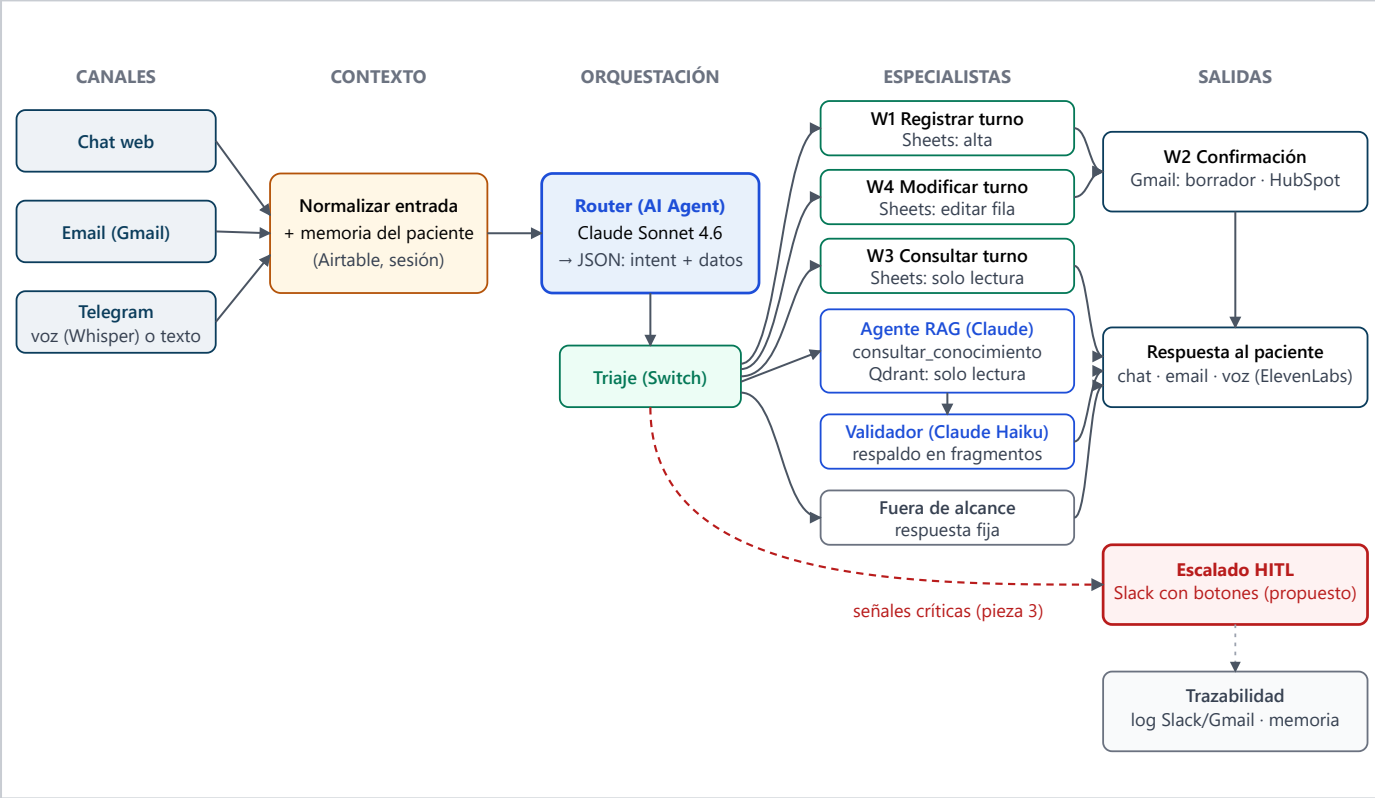
> **Supuestos.** Los números de esta sección no provienen de la clínica real: son supuestos razonables para una clínica ambulatoria mediana, declarados para poder medir la mejora. Se validan en el piloto (pieza 3, KPIs).

Tarea manual	Quién la hace hoy	Volumen diario (supuesto)	Tiempo por gestión (supuesto)	Minutos por día
Sacar un turno nuevo	Administrativas de la Central de Turnos	70	4 min	280
Modificar o cancelar un turno	Ídem	38	3 min	114
Consulta informativa (horarios, profesionales, estudios)	Ídem	72	2,5 min	180
Confirmación o recordatorio manual	Ídem	70	1 min	70
Total	**3 administrativas, de 8 a 20 h**	**250 contactos**		**644 min ≈ 10,7 h por día**

- **Horas por mes** (22 días hábiles): ≈ **236 h** de trabajo administrativo repetitivo.
- **Costo** (supuesto, a efectos de la muestra: $ 10.000 por hora administrativa): 236 h × $ 10.000 ≈ **$ 2.360.000 por mes** solo en estas tareas.
- **Calidad** (supuestos): 5 % de los turnos con datos incompletos o duplicados; espera telefónica promedio de 6 minutos en picos; 20 % de los contactos fuera de horario quedan sin respuesta hasta el día siguiente.

2. Arquitectura del sistema multi-agente y mapa de permisos

La coreografía es la de AgendaBot (construido del M1 al M6): un **Router** clasifica cada pedido y un **triaje determinista** (Switch) lo deriva a especialistas con alcance acotado. Ningún agente hace "todo"; los que escriben datos son workers sin LLM, y el único que redacta texto libre (Agente RAG) está controlado por un validador.



Línea continua: delegación. Línea roja: escalado a humano. Los especialistas devuelven JSON al Manager; ninguno se comunica directamente con otro.

Fichas de los agentes

Rol	Misión	System Prompt constitutivo (extracto)	Herramientas	Entrega (JSON → a quién)
Router (AI Agent, Claude Sonnet 4.6)	Entender el pedido y extraer datos; no responde al paciente	"Clasificá en una taxonomía CERRADA: CREAR_TURNO, MODIFICAR_TURNO, CONSULTAR_TURNO, INFO, FUERA_DE_ALCANCE... No calcules fechas; extraé solo números... No inventes datos."	Memoria de sesión; contexto de Airtable	`{intent, nombre, motivo, dia, mes, hora, *_ref, email}` + `riesgo` (propuesto, pieza 3) → Contrato de datos → Switch
W1 Registrar turno (sin LLM)	Dar de alta un turno validado	— (regla determinista)	Sheets `Agenda_Turnos`: alta	`{ok, id_turno, fecha, hora}` → W2
W4 Modificar turno (sin LLM)	Reprogramar o cancelar el turno identificado	—	Sheets: actualizar la fila del turno	`{ok, id_turno, estado}` → W2
W3 Consultar turno (sin LLM)	Listar los turnos de la persona	—	Sheets: solo lectura	`{mensaje, turnos[]}` → respuesta
W2 Confirmación (sin LLM)	Armar la confirmación en lenguaje claro	Plantilla fija	HubSpot (contactos) y Gmail (borrador), escritos por nodos del Manager a continuación	`{mensaje}` → HubSpot (contacto) y Gmail (borrador)
Agente RAG (AI Agent, Claude Sonnet 4.6)	Responder consultas informativas con la base documental	"Usá EXCLUSIVAMENTE los fragmentos de consultar_conocimiento... Regla 'No sé'... Citá la fuente... Canal de voz: máximo 200 caracteres."	`consultar_conocimiento` (Qdrant, Top-K 5, Min Score 0,60); memoria del paciente	`{respuesta, fragmentos}` → Validador
Validador (Claude Haiku 4.5)	Auditar cada respuesta del RAG contra los fragmentos del turno	"Aprobá solo si cada dato concreto está respaldado por los fragmentos recuperados."	—	`{aprobado, motivo}` → si rechaza, sale una respuesta segura
Resumidor de memoria (Claude)	Consolidar la charla cada 5 mensajes	"Resumen analítico, no transcripción; datos clave."	Airtable `Memoria_M6`: upsert	`{resumen, datos_clave, estado}` → Airtable

Context Engineering: qué recibe cada sub-workflow

Destino	Recibe	No recibe (a propósito)
Router	Mensaje actual, estado del caso, resumen de la última charla, datos clave del paciente, canal	Agenda completa, base documental
Workers de turnos	Solo el JSON del contrato (nombre, motivo, fecha, hora, email, turno de referencia)	Historial de chat, memoria
Agente RAG	Pregunta, memoria del paciente (solo para personalizar) y los fragmentos recuperados **en ese turno**	Datos de turnos de otras personas
Validador	Pregunta, respuesta propuesta y fragmentos	Memoria, historial
Escalado HITL (propuesto)	Resumen del caso, señal crítica detectada, últimos 3 mensajes, contacto	Audios (se descartan, pieza 7 del M6)

Mapa de permisos por rol (mínimo privilegio)

L = lectura · **E** = escritura · **L/E** = ambas · — = sin acceso. Cada rol accede solo a lo que necesita su misión.

Rol	Sheets `Agenda_Turnos`	Airtable `Memoria`	Qdrant (base documental)	Gmail	HubSpot	Slack	Telegram
Router (agente)	—	— (el contexto se lo pasa el Manager)	—	—	—	—	—
Manager (orquestación)	L (turnos de la persona)	L/E (solo su tabla)	—	E (borradores, respuesta en el hilo, log interno)	—	E (`#soporte`)	E (solo al mismo `chat_id`)
W1 Registrar turno	E (alta de fila)	—	—	—	—	—	—
W4 Modificar turno	L/E (solo la fila del turno)	—	—	—	—	—	—
W3 Consultar turno	L	—	—	—	—	—	—
Confirmación (W2 + contacto)	—	—	—	E (borrador)	L/E (solo contactos)	—	—
Agente RAG	—	L (memoria del paciente)	L	—	—	—	—
Validador	—	—	—	—	—	—	—
Resumidor de memoria	—	E (upsert en su tabla)	—	—	—	—	—
Escalado HITL (propuesto)	—	L	—	E (reenvío a coordinación)	—	L/E (mensaje y botones)	—
Ingesta de la base (manual)	—	—	E	—	—	—	—

Ajustes para llegar a este mapa (hoy varias credenciales tienen más alcance que el necesario): - **Google:** una cuenta de servicio con acceso solo a la planilla del módulo, y una credencial de solo lectura para W3; hoy es una credencial OAuth con acceso a todo el Drive. - **Airtable:** token con *scope* a la tabla del módulo y sin permiso de borrado. - **Qdrant:** clave de solo lectura para la herramienta RAG; la de escritura, solo para la ingesta manual. - **HubSpot:** *scopes* solo de contactos, sin deals ni borrado. **Slack:** bot limitado al canal de soporte. - **Gmail:** al paciente nunca se le envía un correo nuevo sin revisión: queda como borrador. - **OpenAI y ElevenLabs:** límite de gasto mensual.

3. Propuesta de valor y semáforo de riesgo (HITL)

Propuesta de valor

La Central de Turnos atiende las 24 horas, por el canal que el paciente ya usa, y el equipo administrativo deja de repetir tareas para ocuparse de los casos que necesitan una persona. El paciente saca, cambia o consulta su turno por chat, email o un audio de Telegram, y recibe la respuesta en segundos; las preguntas frecuentes se contestan con la información oficial de la clínica, citando la fuente; y todo lo sensible (una urgencia, un reclamo, un tema de dinero) llega a un humano con el caso ya resumido.

KPIs (definidos antes de implementar)

Línea de base: el baseline supuesto de la pieza 1. Se miden durante un piloto de 4 semanas con los logs de n8n y la planilla de turnos.

KPI	Cómo se mide	Línea de base (supuesta)	Meta del piloto
Tasa de resolución autónoma	Gestiones cerradas sin intervención humana / total	0 %	≥ 60 %
Horas administrativas liberadas	(gestiones autónomas × minutos del baseline) / 60	0 h	≥ 120 h por mes
Respuestas informativas correctas	Muestra semanal auditada contra la base documental	—	≥ 95 % (en el M5: 5 de 5 en validación ciega)
Escalados correctos	Casos con señal crítica que llegaron a un humano / casos con señal crítica	—	100 %
Turnos con datos incompletos o duplicados	Revisión de la planilla	5 %	< 1 %
Tiempo de respuesta	Del mensaje a la respuesta	6 min de espera en picos (hoy, en el prototipo: 15 a 21 s)	≤ 20 s en texto y en voz
Contactos fuera de horario sin respuesta	Mensajes fuera de 8–20 h sin contestar	20 %	0 %
Turnos sacados fuera de horario (impacto en ingresos)	Turnos registrados entre las 20 y las 8 h / total	0 %	≥ 10 %
Ausentismo (impacto en ingresos)	Turnos sin presentación / turnos dados	Supuesto: 15 %	≤ 10 % con recordatorios (prioridad 2)

Semáforo operativo de riesgo

Nivel	Acciones	Autonomía
🟢 **Verde**	Registrar logs y memoria; responder consultas informativas validadas; consultar los turnos propios; dar de alta un turno con datos completos; actualizar un contacto en HubSpot; avisos fijos (fuera de alcance, audio ilegible)	**100 % autónomas**
🟡 **Amarillo**	Reprogramar o cancelar un turno; enviar una confirmación por email (queda como **borrador** en Gmail); respuesta que el validador rechazó	**100 % autónomas, sin congelamiento**; además quedan en un reporte que un humano audita una vez por día
🔴 **Rojo**	Señales de **urgencia médica** ("dolor en el pecho", "no puedo respirar"); **reclamos o amenazas legales**; **dinero**: reintegros, cobros, diferencias de cobertura; pedidos de **historia clínica** o datos de otra persona; **riesgo de abandono (churn)**: más de 2 cancelaciones del mismo paciente en 30 días; 2 fallas de comprensión seguidas	**Congelamiento + supervisión humana obligatoria**

Frontera taxativa: solo las acciones rojas congelan el flujo y exigen a un humano; las verdes y amarillas se ejecutan solas (el amarillo, con auditoría posterior).

En rojo, el bot no resuelve: responde una frase fija ("Tu consulta la tiene que ver una persona del equipo; ya le avisé") y, ante una urgencia médica, indica de inmediato la **guardia 24 h** sin esperar a nadie.

Protocolo de escalado forzado (Slack con botones)

1. **Detección:** antes del Router, nodos IF y Switch (sin código) buscan las señales rojas (lista de palabras y patrones) y el Router marca `riesgo: "alto"` cuando las infiere. Cualquiera de los dos dispara el escalado; no se le deja al modelo la decisión de **no** escalar.
2. **Congelamiento:** el flujo se detiene en un nodo **Slack › Send and Wait for Response** dirigido a `#soporte`, con el resumen del caso, la señal detectada y los últimos 3 mensajes.
3. **Botones: Tomar el caso** (una persona contacta al paciente y el bot no responde más en esa conversación), **Responder con plantilla** (el bot envía el texto aprobado) o **Descartar** (falso positivo; queda registrado para mejorar la detección).
4. **Tiempo de espera:** si nadie responde en 15 minutos en horario laboral, se reenvía a la coordinación por email; fuera de horario, el paciente recibe el teléfono de la guardia.
5. **Trazabilidad:** cada escalado y su decisión quedan en la memoria del paciente (Airtable) y en el log, para auditar sesgos y falsos positivos cada semana.

Estado: el log a Slack, el borrador de Gmail y el validador ya funcionan en el M6; el nodo de aprobación con botones es la incorporación propuesta en este diseño.

4. Scorecards y versión de portafolio

Los agentes razonan con dos rúbricas fijas y públicas para el equipo, de modo que la misma entrada dé siempre la misma decisión y cada decisión cite su evidencia.

Scorecard A — Validación de respuestas informativas (implementada)

La usa el **Validador** (Claude Haiku) sobre cada respuesta del Agente RAG. La evidencia son **los fragmentos de la base documental recuperados en ese mismo turno**; nada de lo que dice la respuesta puede salir de otro lado.

Criterio	Pregunta que se hace	Evidencia exigida	Si falla
1. Respaldo de cada dato	¿Cada dato concreto sobre la clínica (teléfonos, mails, profesionales, horarios, precios, cifras, direcciones, servicios) está en los fragmentos? Saludos, el nombre del paciente y la sugerencia de llamar a la Central de Turnos no cuentan como datos	Texto de los fragmentos	**Rechazo** → sale la respuesta segura: "No cuento con ese dato en la documentación de la clínica..."
2. Cita de fuente	Si la respuesta usa datos de los fragmentos, ¿incluye al menos una cita `[Fuente: …]`?	La cita	Rechazo
3. Regla "No sé"	Si la respuesta dice que no tiene el dato, ¿se abstiene de agregar datos ausentes de los fragmentos?	Fragmentos	Rechazo
Excepción	Un saludo o una respuesta sin datos de la clínica se aprueba aunque no haya fragmentos	—	—

Los fragmentos que recibe el validador son solo los recuperados **en ese turno**: si el agente no consultó la base, el validador recibe "(el asistente no consultó la base documental)" y cualquier dato concreto queda sin respaldo.

Salida: `{aprobado: true|false, motivo}`. Resultado en el M5: 5 de 5 respuestas correctas en la validación ciega y 0 falsos rechazos del validador en la regresión.

Scorecard B — Prioridad y ruta de cada pedido (diseño)

La aplica el **triaje**, armado con nodos **IF y Switch** de n8n (sin código), con los datos que extrae el Router. Puntaje de 0 a 100; **cada criterio rojo alcanza por sí solo el umbral de escalado**, para que la rúbrica coincida con el semáforo de la pieza 3. Las listas de palabras clave (urgencias, dinero y temas legales) salen de un **protocolo escrito y versionado** por la dirección médica y la administración: es la evidencia documental contra la que se puntúa.

Criterio	Peso	Cómo se puntúa	Evidencia
Señal clínica de alarma	35 %	35 si aparece una palabra o patrón de la lista de urgencias	Texto del mensaje (y transcripción si fue audio)
Dinero, aspecto legal o datos sensibles	25 %	25 si menciona reintegro, cobro, cobertura, reclamo, abogado, denuncia, historia clínica o datos de otra persona	Texto del mensaje
Riesgo de abandono (churn)	20 %	20 si tiene más de 2 cancelaciones en 30 días	Planilla de turnos y memoria (Airtable)
Confianza del entendimiento	20 %	10 con una falla de comprensión o un audio ilegible; 20 con dos seguidas	Contrato de datos y evaluación de la transcripción

Puntaje	Ruta
0–9	🟢 Autónomo (flujo normal)
10–19	🟡 Autónomo, sin congelamiento, con auditoría diaria
20 o más	🔴 Escalado forzado a Slack (pieza 3)

Cualquier criterio rojo suma 20 o más por sí solo: **una urgencia, un tema de dinero o legal, un riesgo de churn o dos fallas seguidas siempre llegan a un humano**.

Versión de portafolio (anonimizada)

Asistente de turnos multicanal con IA para una clínica ambulatoria. Diseño y construcción, en n8n (low-code: la lógica de decisión vive en nodos visuales y agentes; el código se limita a dar formato a los datos), de un sistema multi-agente que atiende la central de turnos por chat, email y notas de voz. Un agente clasificador entiende el pedido; especialistas acotados registran, modifican y consultan turnos en la agenda; un agente de conocimiento responde con la documentación oficial y un segundo modelo audita cada respuesta antes de enviarla. Incluye memoria del paciente, respuesta por voz de menos de 200 caracteres, protección de datos (los audios no se guardan) y un semáforo de riesgo que deriva urgencias, reclamos y temas de dinero a una persona. **Resultados esperados del piloto:** 60 % de resolución autónoma, más de 120 horas mensuales liberadas y atención las 24 horas. *Stack:* n8n, Claude (Anthropic), Qdrant, Whisper, ElevenLabs, Google Sheets, Airtable, HubSpot, Gmail, Slack y Telegram.