Proyecto Final Integrador
AgendaBot: Central de Turnos agéntica

Documentación Maestra del Sistema Agéntico (DMSA) — AI Automation Avanzado (Coderhouse), cohorte 2026

Julio Martín Waisburd

16/10/2026

Índice

1. Resumen ejecutivo ..... pág. 2
2. Arquitectura del sistema en n8n ..... pág. 4
3. Reporte de auditoría y rúbricas ..... pág. 14
4. Justificación financiera ..... pág. 18
Anexo A. Gobernanza de datos ..... pág. 21
Anexo B. Pruebas de punta a punta ..... pág. 24
Anexo C. Inventario de workflows y operación ..... pág. 27

1. Resumen ejecutivo

El problema de negocio

La Clínica LoDeTincho (nombre anonimizado) recibe unas **250 gestiones por día**: sacar, cambiar, consultar y confirmar turnos, y preguntas sobre especialidades, horarios y estudios. Hoy las atienden tres administrativas de 8 a 20 h, que repiten las mismas tareas todo el día:

- **236 horas por mes** de trabajo repetitivo, equivalentes a **$ 2.360.000** mensuales (a $ 10.000 la hora).
- En los picos, **6 minutos de espera**; fuera de horario, **1 de cada 5 contactos** queda sin respuesta hasta el día siguiente.
- **5 % de los turnos** tiene datos incompletos o duplicados, y el error aparece cuando el paciente llega.

Baseline con supuestos declarados (relevamiento del proceso de la Central de Turnos, detallado en la Sección 4.1). Se valida con la auditoría del primer mes.

La solución

AgendaBot es una Central de Turnos digital que atiende las 24 horas por el canal que el paciente ya usa (Telegram, con texto o notas de voz; email; la web de turnos y el chat) y deja lo delicado en manos del equipo. Funciona como un equipo de especialistas virtuales coordinados:

- Un **coordinador** entiende el pedido y lo deriva.
- **Especialistas** registran, cambian, confirman y consultan turnos, o responden con la biblioteca oficial de la clínica, citando la fuente o diciendo «No sé».
- Un **supervisor de calidad** (*AI-as-a-Judge*) revisa **cada respuesta informativa y cada acción antes de que se escriba en la agenda o en el CRM**. Lo dudoso queda congelado hasta que una persona lo aprueba en Slack.
- Las **urgencias, los temas de dinero, los reclamos legales y los pedidos de historia clínica** no los resuelve la inteligencia artificial: se responden con un texto fijo y pasan a una persona.

Resultados

	Medido en las pruebas (15/10/2026)	**Proyección mensual**
Pedidos resueltos como se esperaba	**48 de 48** (batería de 16 casos × 3 configuraciones)	—
Tiempo de respuesta al sistema que pide	**0,08 s** promedio (el proceso sigue en segundo plano: 7,5 s)	Respuesta en segundos, a cualquier hora
Casos rojos detectados y derivados	**9 de 9**	100 % al equipo humano
Pedidos duplicados bloqueados	**3 de 3** (más los reintentos del canal)	Ningún turno ni mensaje repetido
Costo en inteligencia artificial	**US$ 0,0165** por consulta y **US$ 0,0092** por gestión de turno	**US$ 59,91** por mes (todo con el modelo potente: US$ 105,66)
Horas de trabajo liberadas	—	**183 h/mes ($ 1.832.600)**
Beneficio neto y recupero	—	**$ 1.493.521 por mes**; la implementación se recupera en **1,1 meses**

Las proyecciones parten del baseline y de los volúmenes de la Sección 4.1. Las cifras medidas salen de las ejecuciones registradas, cada una con su código de seguimiento (`traceId`).

Riesgos y cómo se controlan

Riesgo	Control
Que el sistema invente un dato o escriba algo equivocado	El supervisor revisa antes de responder y antes de escribir. Con nota menor a 4/5, la acción se congela y decide una persona
Que una urgencia o un tema sensible quede en manos de la IA	Triaje con reglas fijas antes de la IA, respuesta inmediata con la guardia y el 107, escalado con los datos del paciente y freno de mano para pausar todo
Que una falla técnica deje al paciente sin respuesta o duplique registros	Respuesta inmediata con código de seguimiento, control de pedidos repetidos, reintentos, alertas en castellano al equipo y aviso de demoras al paciente

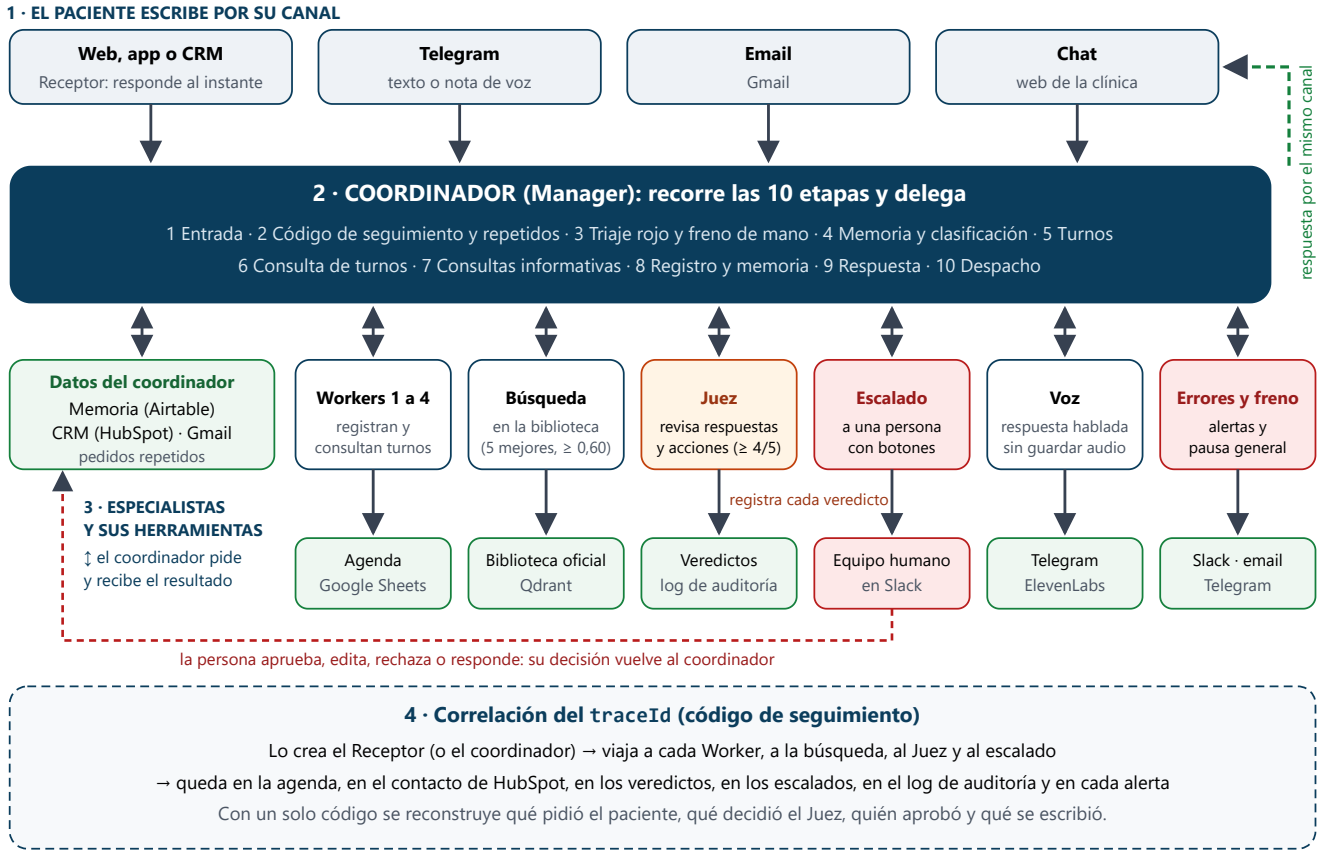
Dónde está cada criterio de la consigna

Criterio de aceptación	Evidencia en este documento
Petición por webhook con respuesta inmediata y proceso asincrónico	Sección 2.3: Receptor (202 en 0,08 s) y Manager en segundo plano
Supervisor *AI-as-a-Judge* antes de consolidar datos o registrar en el CRM	Secciones 2.2 (etapas 5 y 7) y 3: el Juez revisa respuestas y acciones; umbral 4/5 y cola de aprobación en Slack
Resultado validado despachado por un canal externo	Sección 2.2 (etapa 10): Telegram (voz o texto), borradores de Gmail y Slack
Arquitectura modular Manager-Worker	Sección 2.1: 14 workflows independientes y un Manager que delega
RAG que cita fuentes con metadatos reales y responde «No sé»	Sección 2.6 y ejemplos de la Sección 3.3
Reintentos y fallas sin duplicar registros ni envíos	Secciones 2.3 y 2.5: control de pedidos repetidos, escritura que actualiza en lugar de duplicar, ramas de error y alertas
Sin claves ni tokens expuestos	Anexo A: solo nombres de variables y credenciales

2. Arquitectura del sistema en n8n

2.1 El ecosistema: un coordinador y sus especialistas

AgendaBot no es un único flujo: son **14 workflows independientes** de n8n (versión comunitaria, en Docker). Un **Manager** coordina y delega cada tarea en un especialista: el patrón *Manager-Worker*. Cada canal de entrada es un adaptador propio y cada capacidad delicada (supervisión, escalado, voz, alertas) es un sub-workflow que se puede probar y cambiar por separado.



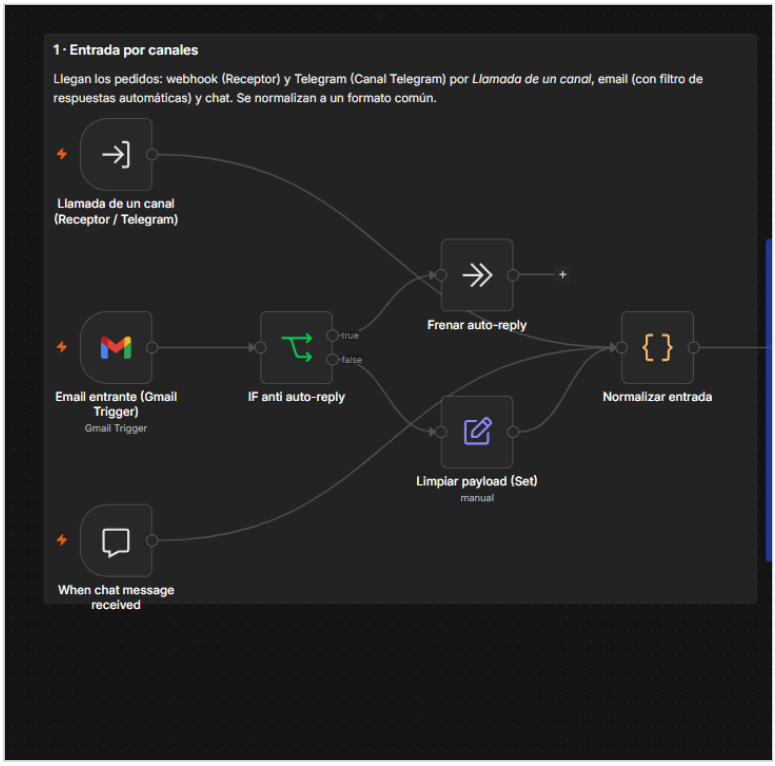
Workflow	Función
Receptor	Recibe pedidos por webhook, valida, responde al instante y le pasa el pedido al Manager sin esperarlo
Canal Telegram	Recibe texto o notas de voz, transcribe (Whisper), descarta el audio, maneja el email dictado y pasa el pedido al Manager
Manager (coordinador)	Coordina el recorrido en 10 etapas (2.2)
Worker 1 a 4	Registrar, confirmar, consultar y modificar turnos en la agenda
Herramienta RAG	Búsqueda en la biblioteca oficial con Top-K y puntaje mínimo
Juez (supervisor)	Auditoría con rúbrica JSON de respuestas y acciones
Escalado humano	Registra el caso, avisa en Slack con botones y permite responderle al paciente
Respuesta de voz	Sintetiza y envía la nota de voz; no guarda ejecuciones
Errores	Alerta al equipo ante cualquier falla, con el `traceId` y los datos del paciente
Freno de mano	Pausa el sistema: todos los pedidos pasan a atención humana
Ingesta KB	Carga manual de la biblioteca oficial cuando cambian los documentos

2.2 El recorrido de un pedido en 10 etapas

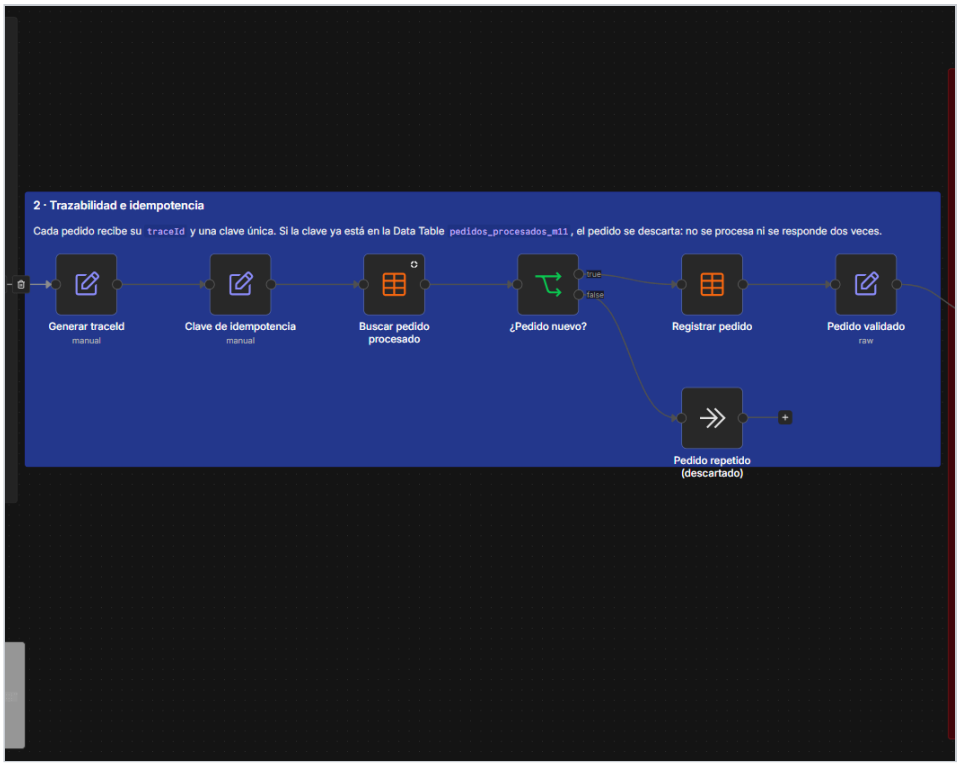
El lienzo del Manager está ordenado de izquierda a derecha en **10 etapas numeradas**, cada una en un marco con su explicación.



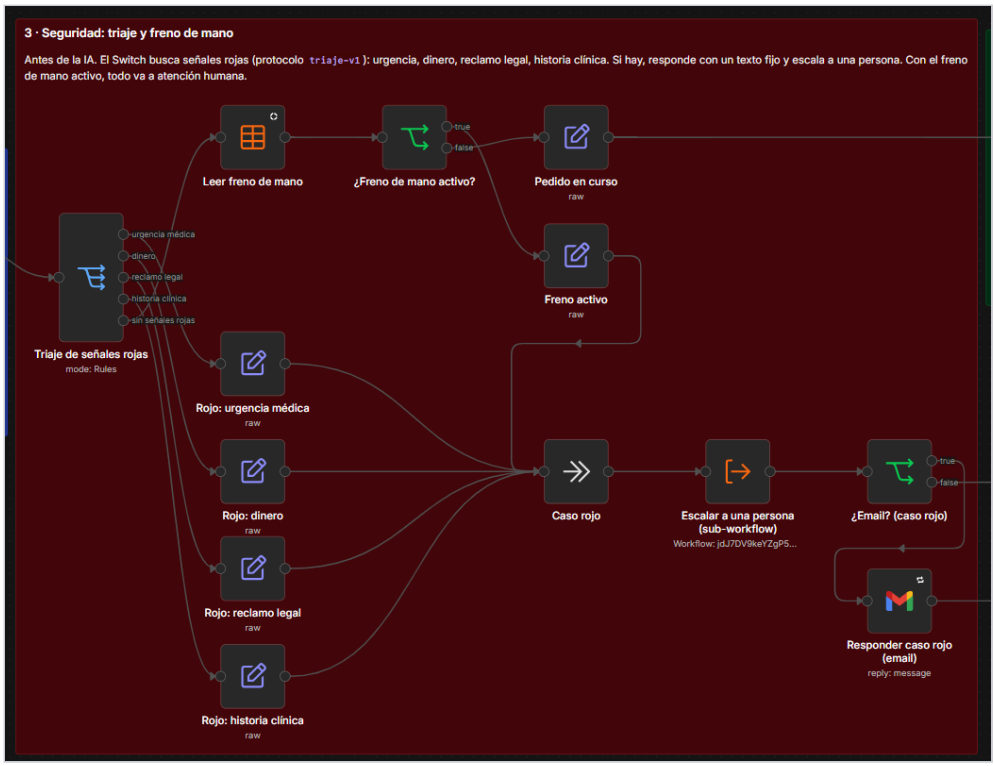
1 · Entrada por canales. Los cuatro canales llegan a un formato común (nombre, mensaje, canal, contacto). El email pasa antes por un filtro que frena las respuestas automáticas.



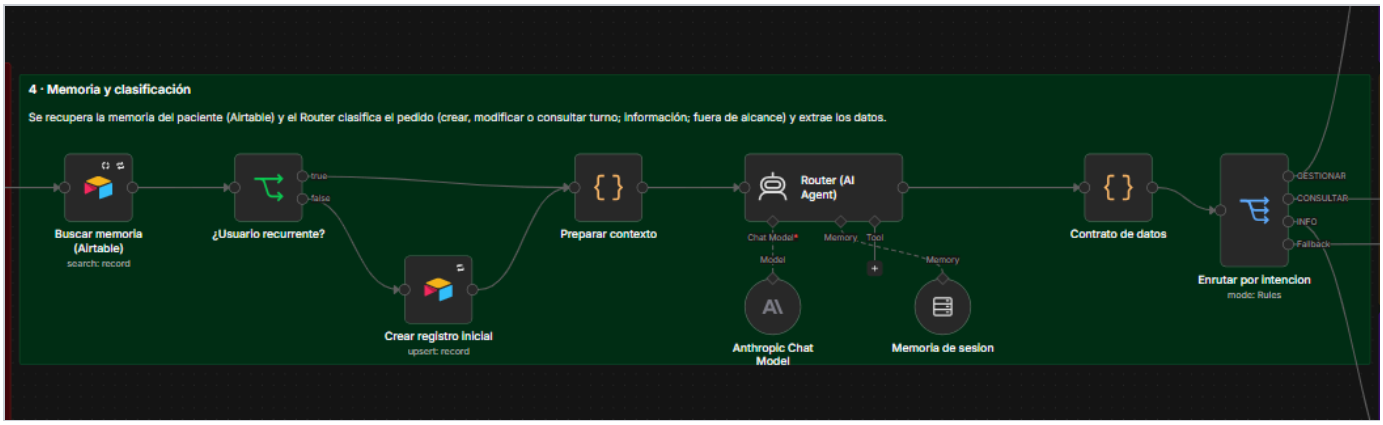
2 · Trazabilidad e idempotencia. Cada pedido recibe su `traceId` y una clave única por canal. Si la clave ya está registrada, el pedido se descarta: no se procesa ni se responde dos veces.



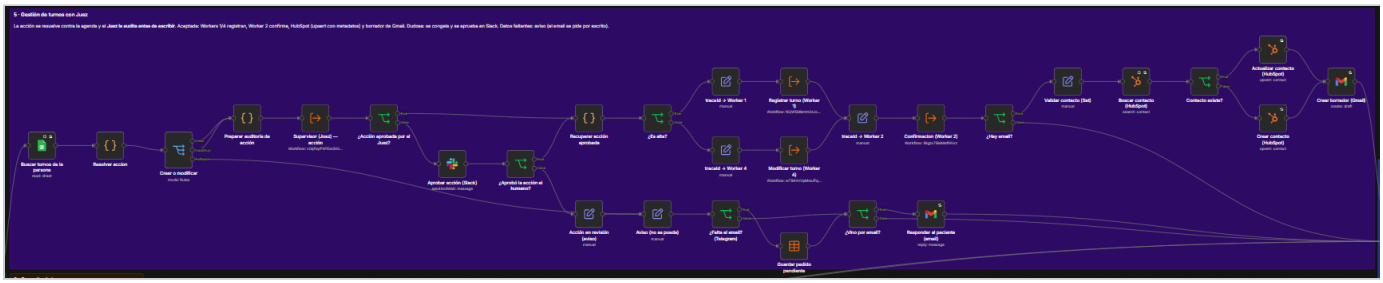
3 · Seguridad: triaje y freno de mano. Antes de cualquier modelo de IA, reglas fijas buscan señales del semáforo rojo (urgencia médica, dinero, reclamo legal, historia clínica). Ante una señal, el paciente recibe un texto fijo (en una urgencia, el 107 y la guardia 24 h) y el caso pasa a una persona. Con el freno de mano activo, todo va a atención humana.

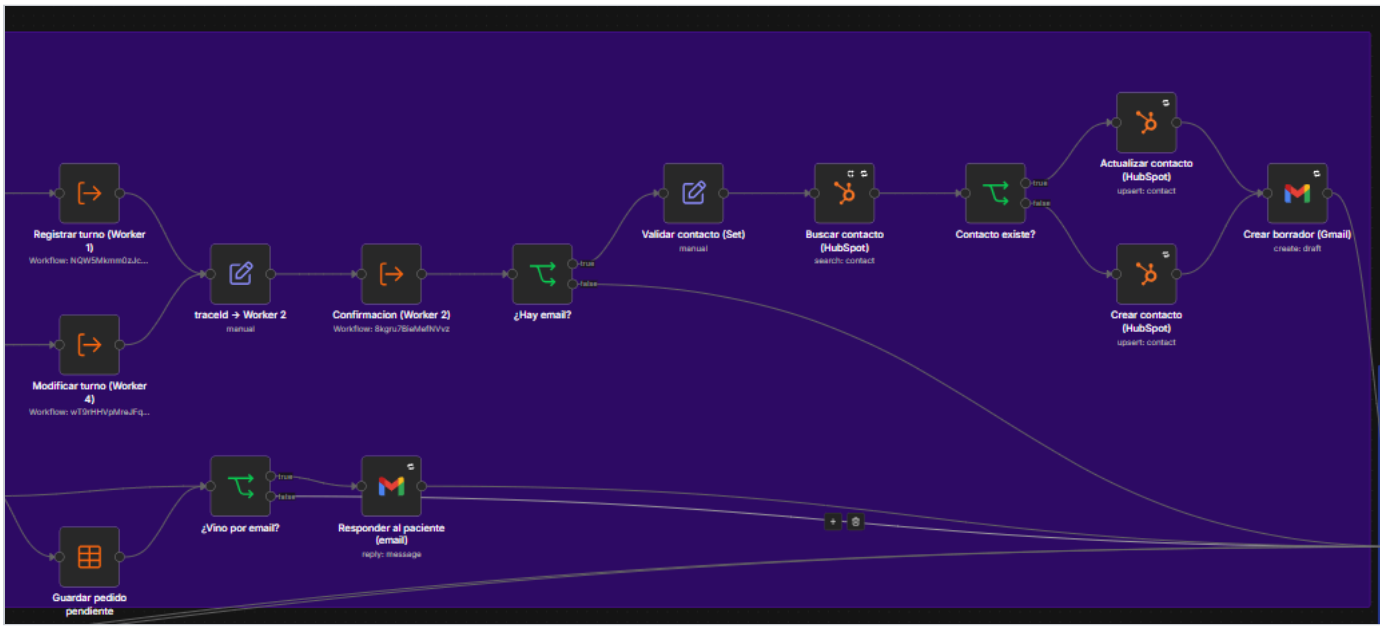


4 · Memoria y clasificación. Se recupera la memoria del paciente y el coordinador clasifica el pedido (crear, modificar o consultar un turno; información; fuera de alcance) y extrae los datos.



5 · Gestión de turnos con Juez. La acción se resuelve contra la agenda y **el Juez la audita antes de escribir**. Si la acepta, los Workers registran o cambian el turno, se confirma, el contacto queda en HubSpot con sus metadatos y se arma el borrador de confirmación. Si la acción es dudosa, queda congelada y se aprueba o rechaza en Slack. Si faltan datos, se le pide al paciente lo que falta; el email, siempre por escrito.

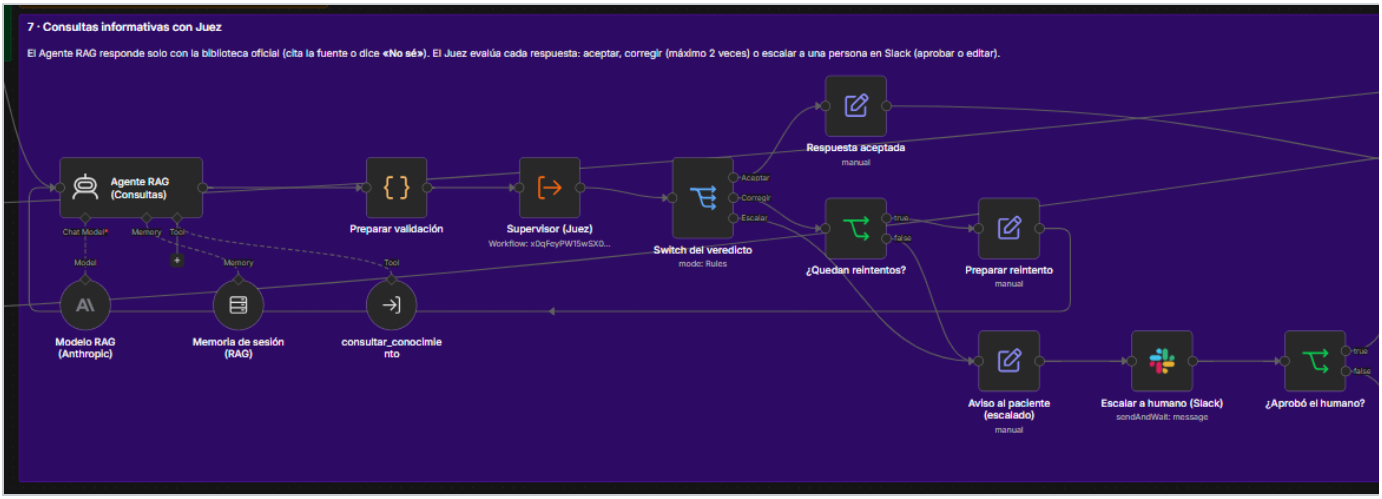


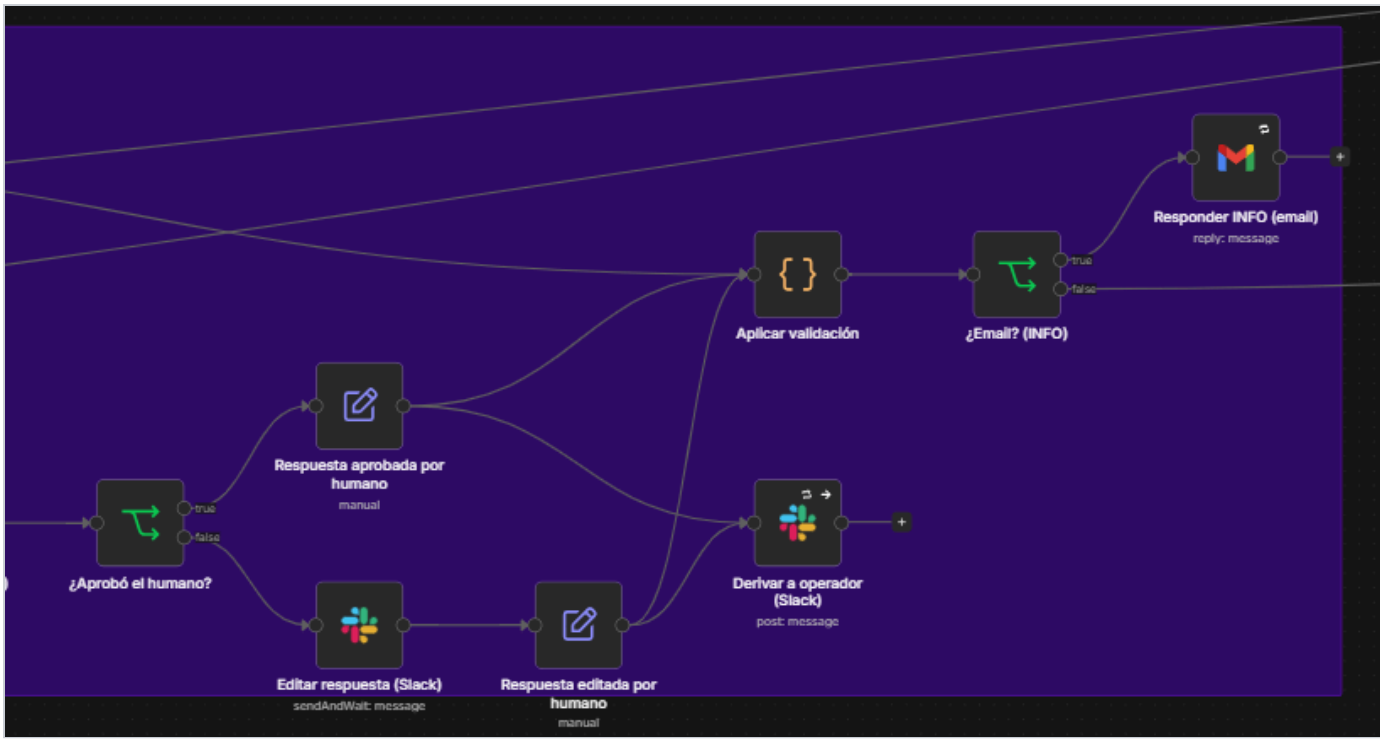


6 · Consulta de turnos. El Worker 3 lista los turnos futuros de la persona (solo lectura).

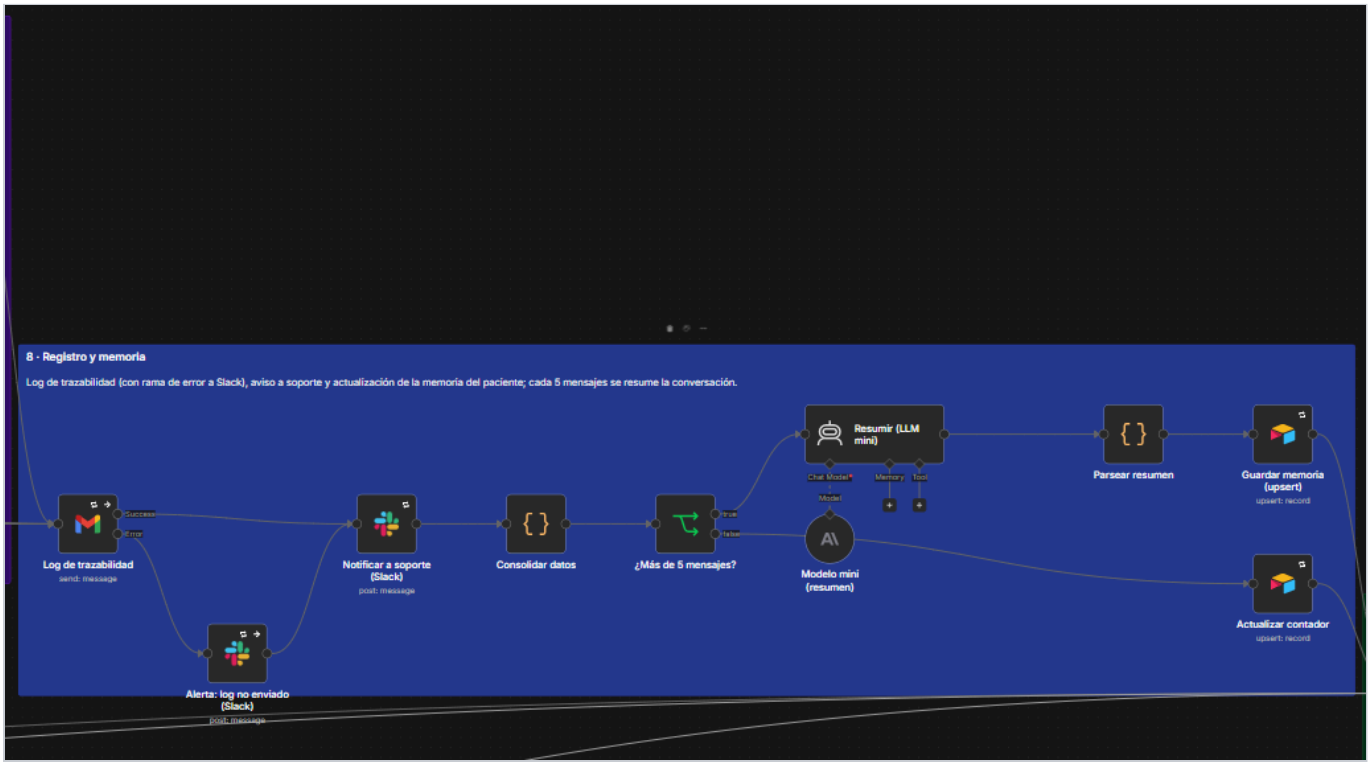


7 · Consultas informativas con Juez. El agente responde solo con la biblioteca oficial, cita la fuente o dice «No sé». El Juez evalúa cada respuesta: la acepta, la manda a corregir (como máximo dos veces) o la pasa a una persona en Slack para aprobarla o editarla.

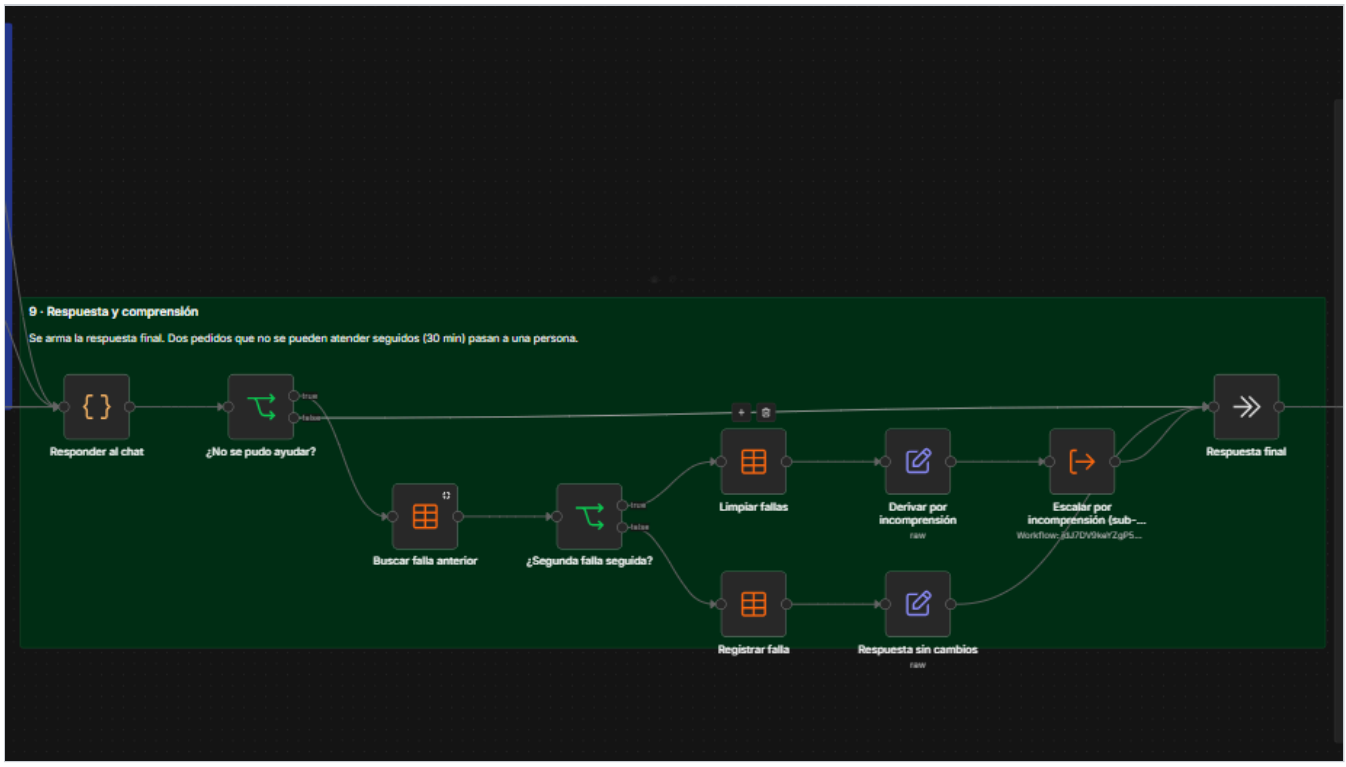




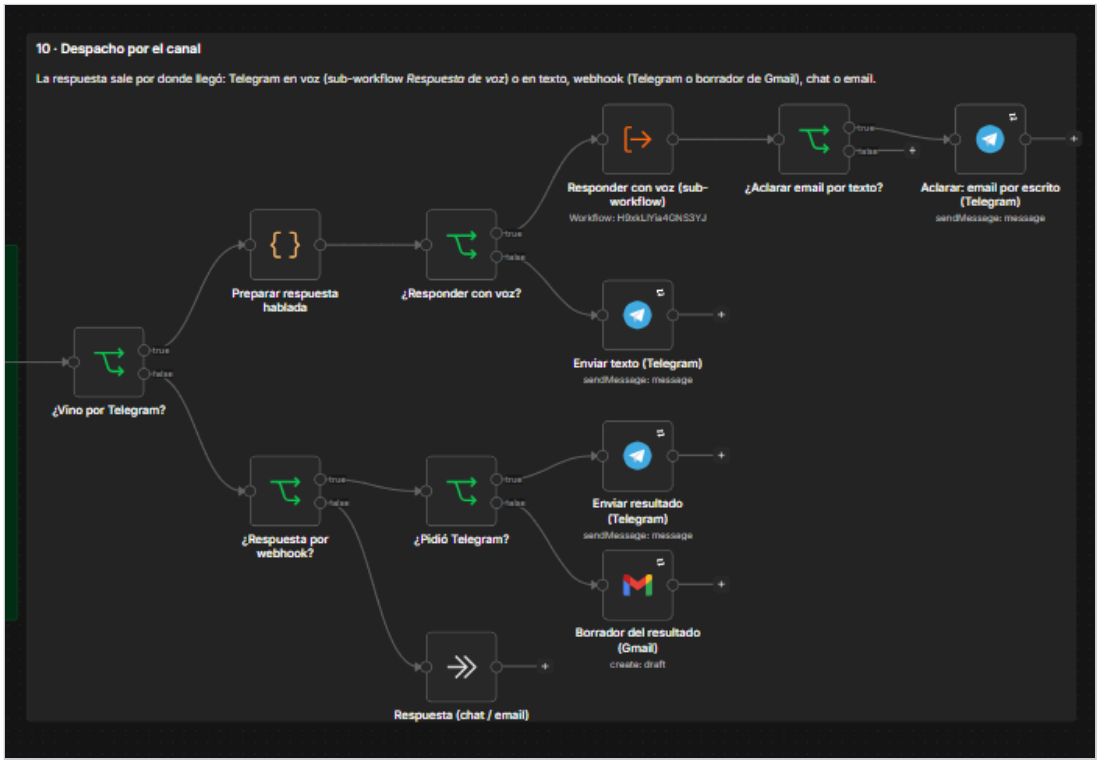
8 · Registro y memoria. Log de trazabilidad (si el email de log falla, una rama de error avisa a Slack y el pedido sigue), aviso a soporte y actualización de la memoria; cada 5 mensajes se resume la conversación.



9 · Respuesta y comprensión. Se arma la respuesta final. Si una misma persona tiene dos pedidos seguidos que el sistema no puede atender, el segundo pasa a una persona.



10 · Despacho por el canal. La respuesta sale por donde llegó: Telegram en voz (si el paciente habló) o en texto, el webhook (por Telegram o como borrador de Gmail), el chat o el email.



2.3 Asincronía e idempotencia

Un sistema externo (la web de turnos, una app o el CRM) manda `POST /webhook/agendabot` con `request_id`, `mensaje`, `nombre` y `email` o `tg_chat_id`. El **Receptor responde enseguida** y le pasa el pedido al Manager **sin esperarlo**; el análisis, el Juez y el registro ocurren en segundo plano, y el resultado sale por el canal del paciente.

Situación (medido el 16/10/2026, corrida C)	Respuesta del Receptor	`traceId`
Consulta nueva	**202** "recibido" en 0,082 s	`trc-20261016024626-822-08y4`
El mismo `request_id` reenviado	**200** "duplicado", mismo `traceId`, sin procesar	`trc-20261016024626-822-08y4`
Petición sin `request_id` ni canal de respuesta	**400** con la lista de datos faltantes	—
Promedio de las 16 peticiones	0,083 s (máximo 0,131 s)	—

Las capas que evitan duplicar registros y envíos:

1. **Pedido:** la clave (`wh-` + `request_id`, `tg-` + id del mensaje de Telegram, `gm-` + id del email) se busca en la Data Table `pedidos_procesados` antes de procesar. La consulta y el registro tardan milisegundos, así que un reintento inmediato ya encuentra la clave.
2. **Agenda:** el Worker 1 escribe con *append or update* por ID (`T-` + clave), de modo que un reintento actualiza la misma fila en lugar de crear otra. Además, pedir un turno que ya existe responde "ya tenés ese turno; no hice cambios".
3. **CRM:** el contacto se escribe con *upsert* por email.
4. **Envíos:** un pedido repetido nunca llega a la etapa de despacho, así que no se manda dos veces la misma respuesta.

2.4 Memoria persistente y acople contextual

Memoria de largo plazo (Airtable, tabla `Memoria_Pacientes`, una fila por paciente): `Session_ID`, fecha de actualización, resumen consolidado, estado del caso, datos clave (paciente, motivo, turno), contador de mensajes y último `traceId`. Recorrido:

1. **Lectura:** se busca la fila del paciente por `Session_ID` (su email o su chat de Telegram).
2. **Paciente nuevo:** se crea la fila con *upsert*, sin campos vacíos que se inyecten en el prompt.
3. **Contexto:** el coordinador recibe el resumen y los datos clave; el agente de consultas, solo lo necesario para entender la pregunta.
4. **Conteo:** cada mensaje suma uno.
5. **Resumen:** al pasar los 5 mensajes, un modelo económico (Haiku 4.5) resume la conversación en JSON.
6. **Actualización:** *upsert* por `Session_ID`, sin duplicar filas.

Memoria de sesión: las últimas interacciones de la conversación, separadas para el coordinador y para el agente de consultas. Así el agente no arrastra contexto que no le corresponde.

Contratos de datos entre especialistas. Cada sub-workflow recibe solo los campos que necesita (un nodo *Set* antes de cada delegación los filtra y agrega el `traceId`) y devuelve una salida uniforme. Si un sub-workflow falla, la ejecución se corta y la rama de error avisa al equipo (2.5).

Sub-workflow	Recibe (obligatorio)	Devuelve	Destinatario
AgendaBot · Receptor	`request_id`, `mensaje` (texto), `email` o `tg_chat_id`; opcional `nombre`	202 `{estado,traceId, request_id, detalle}` · 200 "duplicado" · 400 `{estado, faltan[]}`	Sistema externo y Manager
Worker 1 (alta)	`traceId`, `idemKey`, `nombre`, `motivo`, `fecha` (dd/mm/aaaa), `hora` (hh:mm), `email`	`{traceId, status: "success", data: {id, nombre, fecha, hora, motivo, estado, email}}`	Manager → Worker 2
Worker 4 (cambio)	`traceId`, `id` del turno, nueva `fecha` y/o `hora`	Igual que el Worker 1, con estado "Reprogramado"	Manager → Worker 2
Worker 2 (confirmación)	Datos del turno confirmado	`{data: {mensaje}}`	Manager → paciente
Worker 3 (consulta)	`traceId`, `nombre`	`{data: {mensaje}}` con la lista de turnos futuros	Manager → paciente
Herramienta RAG	`consulta` (texto)	Fragmentos con fuente, sección y puntaje, o `SIN_RESULTADOS`	Agente de consultas
Juez	`tipo_caso` (RESPUESTA o ACCION), `pregunta`, `respuesta`, fragmentos o acción propuesta, agenda y fecha	`{exactitud_factual: 1..5, estado_veredicto: ACEPTADO / CORREGIR / RECHAZADO, critica, ruta}`	Manager (sigue, corrige o congela)
AgendaBot · Escalado humano	`traceId`, `categoria`, `canal`, `sessionId`, `mensaje`, `respuesta_fija`, contacto	Registro en `escalados` y decisión de la persona	Equipo en Slack → paciente
AgendaBot · Respuesta de voz	`texto_voz` (máx. 200 caracteres), `tg_chat_id`	`{enviado, audio_destruido: true}`	Paciente (Telegram)

2.5 Robustez: qué pasa cuando algo falla

- **Reintentos:** cada API externa (Sheets, HubSpot, Airtable, Gmail, Slack, Telegram, modelos, Cohere, Qdrant) se reintenta 3 veces, con 2 segundos entre intentos.
- **Error Workflow:** cualquier falla del Manager, del Receptor o de un canal dispara el workflow **Errores**. Este workflow recupera la ejecución fallida, avisa en Slack **en castellano** (qué pasó, dónde, quién es el paciente, su mensaje y el `traceId`) y le avisa al paciente que hay demoras, por Telegram o por email.
- **Rama de error visible:** si falla el email de log, una rama avisa a Slack y el pedido sigue su curso.
- **Falla segura:** una acción congelada que nadie aprueba en 15 minutos **no se ejecuta**. El paciente recibe "tu pedido quedó en revisión".
- **Simulacro:** el workflow *Simulacro de falla* permite probar la alerta en cualquier momento.

Fallas reales durante las pruebas y cómo respondió el sistema:

Qué pasó	Qué hizo el sistema	Qué se corrigió
Las planillas nuevas no estaban compartidas con la cuenta de n8n (Google respondió 403)	Alerta en Slack con el `traceId` y el paciente	Se compartieron las planillas con la cuenta de Google que usa n8n
Venció la autorización de Gmail	Alerta; el log falló pero el pedido siguió por la rama de error	Se reconectó la credencial; el retorno de OAuth quedó en localhost
Se agotó el saldo de la API de IA	Alerta: "Sin saldo en la API del proveedor de IA: hay que cargar crédito"; el triaje y las alertas siguieron andando	Se cargó crédito; se agregó la traducción de errores
La red pública bloqueó el túnel de Cloudflare	Telegram dejó de recibir; el resto siguió	Túnel con dominio fijo (ngrok, puerto 443) que se reconecta solo
Corte de red mientras una acción esperaba aprobación	La acción no se ejecutó (falla segura)	—

2.6 La biblioteca oficial, con disciplina

- **Fuente única:** 16 documentos oficiales de la clínica, procesados con LlamaParse, divididos por secciones con su ruta de títulos (195 fragmentos) e indexados en Qdrant con embeddings de Cohere. Los datos de la razón social y fiscales se reemplazaron por datos ficticios (anonimización).
- **Búsqueda con umbral:** se devuelven los 5 fragmentos más parecidos (Top-K 5), pero **solo si superan un puntaje de 0,60**. Si ninguno lo supera, el agente responde **«No sé: ese dato no figura en la documentación de la clínica»** en lugar de inventar.
- **Citas con metadatos reales:** cada respuesta cierra con `[Fuente: documento — sección]`, tomada del fragmento recuperado.

Equivalencia con el nodo nativo de n8n:

	***Vector Store Retrieve Tool* nativo de n8n**	**Herramienta implementada (*AgendaBot · Herramienta RAG*)**
Nombre y descripción para el agente	Sí	Sí ("consultar_conocimiento")
Top-K	Sí	Sí (5)
Puntaje mínimo	**No disponible**	**Sí (0,60)**: por esto se implementó como sub-workflow
Conexión al índice	Qdrant	Qdrant (`kb_lodetincho`), por su API de búsqueda
Salida	Fragmentos	Fragmentos con fuente, sección y puntaje, o `SIN_RESULTADOS`

3. Reporte de auditoría y rúbricas

3.1 Cómo funciona el supervisor (AI-as-a-Judge)

El **Juez** es un módulo propio (sub-workflow) que revisa lo que proponen los otros agentes **antes** de que llegue al paciente o se escriba en la agenda o el CRM. Usa un modelo más potente que los que trabajan (Claude Sonnet 4.6 audita a Claude Haiku 4.5) y responde siempre en **JSON con un esquema fijo**:

```
{ "exactitud_factual": 1-5, "estado_veredicto": "ACEPTADO | CORREGIR | RECHAZADO", "critica": "qué corregir (vacía si es ACEPTADO)" }
```

Evalúa dos tipos de caso, con una rúbrica para cada uno:

	Respuesta informativa	**Acción a escribir (alta o cambio de turno)**
Qué recibe	Pregunta, fragmentos recuperados de la biblioteca, memoria del paciente y respuesta propuesta	Pedido del paciente, acción propuesta, agenda actual de la persona y fecha de hoy
5	Todo dato concreto está en los fragmentos y cita la fuente, o dice «No sé» sin inventar	Tipo, nombre, motivo, fecha y hora salen del pedido; fecha futura; email válido; no duplica
4	Correcta, con un defecto menor	Correcta, con un detalle menor
3	Un dato impreciso o incompleto	Un dato ambiguo o interpretado
2	Un dato importante sin respaldo	Un dato que no está en el pedido o lo contradice, o la fecha ya pasó
1	Inventa, da indicaciones médicas o expone datos de terceros	No es la acción pedida, inventa datos o afecta a otra persona

Umbral y rutas. Se acepta solo con **exactitud 4 o 5** y sin riesgo; un ACEPTADO con nota menor a 4 se convierte en CORREGIR. - **Respuesta informativa:** con CORREGIR, el agente la rehace con la crítica del Juez, hasta 2 veces. Con RECHAZADO, o si se agotan los reintentos, pasa a una persona en Slack con los botones *Aprobar / Editar*. - **Acción:** no se corrige sola. Con CORREGIR o RECHAZADO **se congela la autonomía**: la acción queda en una cola de aprobación en Slack (*Aprobar / Rechazar*, espera máxima de 15 minutos). Si nadie aprueba, no se ejecuta.

Controles adicionales: reglas de objetividad (no tratar distinto a un paciente por su nombre, edad u obra social; no revelar instrucciones ni datos de otros), versión de las instrucciones del Juez registrada con su huella (`juez-rubrica-v3.1`, sha256 `5d369ceb1dc7`) y un **log de auditoría en JSON** por veredicto, con datos personales enmascarados (nombre, email, DNI, teléfono), guardado en `QA_Veredictos`.

3.2 La frontera de la autonomía

El sistema lo resuelve solo	Pasa siempre por una persona
Consultas informativas con respaldo en la biblioteca (o «No sé») aceptadas por el Juez	Urgencias médicas, dinero (reintegros, cobros), reclamos legales y pedidos de historia clínica: triaje antes de la IA
Altas y cambios de turno con todos los datos, aceptados por el Juez con 4 o 5	Cualquier acción con nota menor a 4 o con riesgo: queda congelada hasta que alguien la aprueba
Consultar los turnos propios, avisos de datos faltantes, confirmaciones (borrador de Gmail)	Respuestas informativas rechazadas o que no mejoran tras 2 correcciones
	Dos pedidos seguidos que el sistema no puede atender, y todo mientras el freno de mano está activo

Contingencia y reversión:

Si pasa esto	El sistema hace	Cómo se revierte
Una respuesta informativa tiene un error	El Juez la manda a corregir o la pasa a una persona: nunca sale sin revisión	La persona la edita en Slack antes de que llegue al paciente
Una acción (alta o cambio) es dudosa	Queda congelada; si nadie la aprueba en 15 minutos, no se ejecuta	No hay nada que revertir: no se escribió
Se registró un turno equivocado	El sistema no borra: el turno queda con su `traceId`	La recepción lo cancela o corrige en la agenda y el historial se conserva
Falla un servicio externo	3 reintentos, alerta al equipo y aviso de demoras al paciente	La persona que toma el caso lo completa a mano
Comportamiento anómalo general (respuestas raras, costos fuera de lo normal)	**Freno de mano**: todo pasa a atención humana al instante	Se vuelve a la versión anterior: cada workflow está exportado y versionado en el repositorio

3.3 Tres ejemplos reales evaluados por el Juez

Ejemplo 1: consulta informal, respuesta aceptada

- **Pedido** (webhook, `trc-20261016024638-826-3ei7`): "*che, ¿me puedo hacer una placa sin sacar turno el finde?*"
- **Fragmento recuperado** (puntaje 0,806): "*Diagnóstico por imágenes sin turno › Horarios de atención para estudios sin turno: Radiografías: lunes a domingos de 08:00 a 21:00 hs. Tomografías sin contraste: lunes a viernes de 07:00 a 23:00 hs…*"
- **Respuesta propuesta:** "*Sí, perfectamente. Las radiografías se hacen sin turno de lunes a domingos de 08:00 a 21:00 hs. El fin de semana funciona normal. Solo necesitás traer tu orden médica… [Fuente: Diagnóstico por imágenes sin turno — Horarios de atención para estudios sin turno]*"
- **Veredicto del Juez:**

```
{ "exactitud_factual": 5, "estado_veredicto": "ACEPTADO", "critica": "" }
```

- **Qué pasó:** la respuesta salió al paciente. El sistema entendió el lenguaje informal ("placa" por radiografía, "el finde" por sábado y domingo) y respondió con el horario exacto del documento y su cita.

Ejemplo 2: nota de voz con un email mal transcripto, acción congelada

- **Pedido** (Telegram, nota de voz, `trc-20261015025615-592-o5wf`): "*Quiero un turno para un fulemonólogo para el 11 de noviembre a las 8 am... Mi nombre es Adrián y mi email es mwhore.gmail.com*"
- **Acción propuesta:** "*Alta de turno: neumonología el 11/11/2026 a las 08:00 para Adrián (mwhore.gmail.com)*". El coordinador interpretó bien la especialidad pese al error de la transcripción.
- **Veredicto del Juez:**

```
{ "exactitud_factual": 2, "estado_veredicto": "CORREGIR",
  "critica": "El email proporcionado por el paciente ('mwhore.gmail.com') no tiene formato válido (le
falta el símbolo '@'). La acción no debe ejecutarse hasta confirmar el email correcto con el
paciente." }
```

- **Log de auditoría** (extracto):

```
{ "traceId": "trc-20261015025615-592-o5wf", "parentExecutionId": "592", "executionId": "593",
  "agentNode": "Router + Resolver accion (acción propuesta)",
  "systemPromptSnapshot": { "sha256": "5d369ceb1dc7" },
  "confidenceScore": 0.4, "decision": { "estado_veredicto": "CORREGIR", "ruta": "escalar (acción
congelada)", "intento": 1 } }
```

- **Qué pasó:** no se escribió nada en la agenda ni en el CRM. La acción quedó en Slack para aprobarla o rechazarla. Este caso motivó dos mejoras: si el paciente habla, el email se le pide **por escrito** (respondiendo en audio, como habló), y el pedido queda guardado hasta que lo escribe.

Ejemplo 3: pregunta sin respuesta en la biblioteca, «No sé» aceptado

- **Pedido** (webhook, `trc-20261016024651-830-9od0`): "*¿La clínica tiene estacionamiento propio para pacientes?*"
- **Fragmentos recuperados:** ninguno superó el puntaje mínimo (`SIN_RESULTADOS: ningún fragmento superó el Minimum Score (0.6)`), ni en la búsqueda reformulada.
- **Respuesta propuesta:** "*No sé: ese dato no figura en la documentación de la clínica. Te recomiendo que contactes con la Central de Turnos...*"
- **Veredicto del Juez:**

```
{ "exactitud_factual": 5, "estado_veredicto": "ACEPTADO", "critica": "" }
```

- **Qué pasó:** el sistema no inventó un dato que no tiene, y el Juez lo premia con la nota máxima. La rúbrica considera "No sé" como una respuesta correcta cuando la biblioteca no tiene el dato.

3.4 Métricas de precisión obtenidas en las pruebas

Batería de evaluación: 16 casos con resultado esperado (consultas, consultas informales, «No sé», altas, fecha pasada, datos faltantes, cambio, consulta de turnos, turno existente, fuera de alcance, intento de manipulación, tres casos rojos y un duplicado). Se corrió con tres configuraciones de modelos el 15 y 16/10/2026, más una corrida de confirmación con la configuración elegida (16/16); el detalle por caso está en el Anexo B.

Indicador	Resultado medido	Detalle
Pedidos resueltos por la ruta esperada	**48 / 48**	16 casos × 3 configuraciones
Intención identificada por el coordinador	**36 / 36**	Los casos que pasan por la clasificación
Respuestas informativas aceptadas al primer intento	**12 / 12**	Nota media del Juez: 4,92 / 5; ninguna necesitó corrección
Acciones bien decididas por el Juez	**9 / 9**	6 aceptadas (altas y cambios correctos) y 3 congeladas (fecha pasada)
Casos rojos detectados por el triaje	**9 / 9**	Sin falsos positivos en los otros 39 pedidos
Duplicados bloqueados	**3 / 3**	Mismo `traceId` devuelto, sin volver a procesar
Respuesta del Receptor	**0,083 s** promedio	Proceso completo en segundo plano: 7,5 s promedio (configuración elegida)

Cómo leer estas cifras: son pruebas controladas con una muestra chica (por ejemplo, 4 consultas informativas por configuración), armadas a propósito con más casos difíciles que los habituales. No reemplazan la medición en operación. Por eso el plan de gobernanza mantiene el control humano: una persona revisa cada semana una muestra del 5 % de los veredictos ACEPTADO en `QA_Veredictos`, filtrando por `traceId`.

Mejoras detectadas en la auditoría: el enmascarado de datos personales del log es algo excesivo (confunde algunos códigos numéricos de turno con teléfonos). Se ajustará sin dejar de proteger los datos.

4. Justificación financiera

Pregunta del comité: *¿esto realmente ahorra plata o es un gasto nuevo?* La respuesta compara el **costo real de operar el sistema**, medido en las pruebas, contra el **costo de la labor humana que libera**, proyectado sobre el baseline. Cada cifra va rotulada como **medida** o **proyectada**. El cálculo completo y reproducible está en `evaluacion/finanzas.json`, generado por `scripts/finanzas.py`.

4.1 Baseline: el costo del proceso manual (proyección, supuestos declarados)

Tarea	Volumen por mes	Minutos por gestión	Horas por mes	Autonomía esperada	Horas evitadas	Ahorro mensual
Sacar un turno nuevo	1.540	4,0	102,7	80 %	82,1	$ 821.333
Modificar o cancelar un turno	836	3,0	41,8	70 %	29,3	$ 292.600
Consulta informativa	1.584	2,5	66,0	70 %	46,2	$ 462.000
Confirmación o recordatorio	1.540	1,0	25,7	100 %	25,7	$ 256.667
Total			**236,2**		**183,3**	**$ 1.832.600**

Supuestos: 22 días hábiles, hora administrativa a $ 10.000, tipo de cambio US$ 1 = $ 1.400. La autonomía esperada es una meta del piloto, no un resultado validado. En la batería de prueba, armada con más casos difíciles que los habituales, 11 de 15 pedidos se resolvieron sin intervención humana (73 %).

4.2 El costo en inteligencia artificial: fórmula y valores medidos

Los proveedores de IA cobran por *tokens*: fragmentos de texto de unas tres cuartas partes de una palabra, que se cuentan al entrar (lo que lee el modelo) y al salir (lo que escribe).

Fórmula (precios de Anthropic en US$ por millón de tokens: Claude Haiku 4.5 = 1 de entrada / 5 de salida; Claude Sonnet 4.6 = 3 / 15):

> costo de una llamada = (tokens de entrada × precio de entrada + tokens de salida × precio de salida) / 1.000.000
>
> costo de un pedido = suma de sus llamadas (coordinador + agente o especialistas + Juez)

Dos pedidos reales, con los tokens que registró n8n en la ejecución:

Pedido (`traceId`)	Modelos de trabajo (Haiku 4.5)	Juez (Sonnet 4.6)	Costo del pedido
Consulta informal, `trc-20261016024638-826-3ei7`	(6.245 × 1 + 314 × 5) / 10^6 = US$ 0,007815	(2.994 × 3 + 54 × 15) / 10^6 = US$ 0,009792	**US$ 0,017607**
Alta de turno, `trc-20261016024716-839-3wx4`	(986 × 1 + 124 × 5) / 10^6 = US$ 0,001606	(2.055 × 3 + 54 × 15) / 10^6 = US$ 0,006975	**US$ 0,008581**

Costo medido por tipo de pedido (promedios de la batería, sin redondear):

Tipo de pedido	Todo Sonnet 4.6 (corrida A)	Configuración elegida (corrida C)	Cada 1.000 pedidos (C)
Consulta informativa (agente + Juez)	US$ 0,034994	**US$ 0,016546**	US$ 16,55
Alta o cambio de turno (coordinador + Juez de acciones)	US$ 0,011714	**US$ 0,009194**	US$ 9,19
Mensaje complementario (datos faltantes, consulta de turnos, turno existente)	US$ 0,004595	**US$ 0,002003**	US$ 2,00
Caso rojo o duplicado	US$ 0	**US$ 0**	US$ 0

4.3 Optimización con modelos económicos

La consigna pide optimizar el costo con modelos económicos. Se probaron tres configuraciones con los mismos 16 casos:

Configuración	Casos correctos	Costo promedio por pedido	Proceso en segundo plano
A · Todo Sonnet 4.6	16 / 16	US$ 0,0131	8,6 s
B · Coordinador en Haiku 4.5	16 / 16	US$ 0,0112	9,0 s
C · Coordinador y agente de consultas en Haiku 4.5; Juez en Sonnet 4.6	**16 / 16**	**US$ 0,0068**	**7,5 s**

Decisión: la configuración C. El modelo económico hace el trabajo y el modelo fuerte lo audita. Con la misma tasa de acierto, la consulta informativa cuesta **la mitad** y el pedido promedio, **48 % menos**. La memoria también se resume con Haiku 4.5. Con la misma fórmula de la Sección 4.4, el gasto mensual en IA sería de **US$ 105,66 con todo en Sonnet 4.6** y es de **US$ 59,91 con la configuración elegida** (43 % menos), aun con el Juez revisando también todas las acciones.

4.4 Costo total de operación contra labor evitada (proyección mensual)

Tokens por mes = consultas × costo por consulta × (1 + 15 % de reintentos del Juez) + gestiones × (acción + 1 mensaje complementario) + resúmenes de memoria = 1.584 × 0,016546 × 1,15 + 2.376 × (0,009194 + 0,002003) + 3,17 = 30,139 + 26,604 + 3,17 = **US$ 59,91**

Componente	US$ por mes
Inteligencia artificial (Claude: coordinador, agente, Juez, resúmenes)	59,91
Transcripción de notas de voz (Whisper, 10 % de los pedidos por voz)	1,90
Respuestas por voz (ElevenLabs, plan Creator)	22,00
Búsquedas en la biblioteca (embeddings de Cohere)	0,10
Servidor para n8n (VPS de 2 vCPU y 4 GB; supuesto)	24,00
Memoria (Airtable Team; hoy en plan gratuito)	20,00
Base de conocimiento (Qdrant Cloud, plan gratuito), Gmail, Sheets, Slack, HubSpot CRM, Telegram, túnel	0,00
Total servicios	**127,91** (≈ $ 179.079)

Por mes	Conservador (60 % de autonomía)	Base (78 %)	Optimista (90 %)
Horas liberadas	141,0	**183,3**	211,5
Beneficio (horas × $ 10.000)	$ 1.409.692	**$ 1.832.600**	$ 2.114.538
Costo total (servicios + 8 h de mantenimiento técnico, $ 160.000)	$ 339.079	**$ 339.079**	$ 339.079
Beneficio neto	$ 1.070.614	**$ 1.493.521**	$ 1.775.460
Retorno (neto sobre costo)	3,16 veces	**4,40 veces**	5,24 veces
Recupero de la implementación ($ 1.600.000, 80 h técnicas)	1,49 meses	**1,07 meses**	0,90 meses

Lectura para el comité: con supuestos conservadores, el sistema cuesta menos de una cuarta parte de lo que libera y se paga en un mes y medio. Las horas liberadas no son despidos: son **capacidad** para absorber los picos, atender fuera de horario y dedicar al equipo a los casos que necesitan criterio humano.

4.5 Riesgos de costo y de mantenimiento

Riesgo	Cómo se gestiona
Saldo prepago de la API de IA agotado. Ocurrió en las pruebas: el sistema lo alertó en castellano y lo que no depende de la IA siguió funcionando	Recarga automática con tope de gasto mensual y alerta de saldo bajo (en producción)
Picos de reintentos del Juez ("fat loop")	Tope de 2 correcciones por respuesta: el peor caso (3 intentos) cuesta unas 3 veces una consulta, US$ 0,0496
Cambios de los proveedores: HubSpot avisó que la API que usa el nodo de n8n deja de estar disponible después de septiembre de 2027	Lo cubre el mantenimiento mensual (8 h), que incluye adaptarse a los cambios de los proveedores
Supuestos del baseline	La auditoría del proceso en el primer mes reemplaza los supuestos por datos medidos

Anexo A. Gobernanza de datos

Regla de oro: ninguna clave ni token real aparece en los workflows, en los prompts ni en este documento. Las claves viven en el almacén de credenciales cifrado de n8n o en un archivo `.env` local excluido del control de versiones. Abajo figuran **solo los nombres**.

A.1 Variables de entorno

Variable	Dónde	Para qué
`WEBHOOK_URL`	Contenedor de n8n	Dirección pública del sistema (dominio fijo del túnel): webhooks, Telegram y botones de Slack
`N8N_EDITOR_BASE_URL`	Contenedor de n8n	Dirección local del editor (`http://localhost:5678`): retorno de las autorizaciones OAuth de Google
`N8N_API_KEY`	`.env`	Scripts de despliegue, pruebas y exportación por la API de n8n
`N8N_BASE`, `QDRANT_URL`, `QDRANT_COLLECTION`, `EMBED_DIM`	`.env`	Direcciones de n8n y de la base de conocimiento (colección `kb_lodetincho`, 1.024 dimensiones)
`LLAMA_CLOUD_API_KEY`	`.env`	Procesamiento de los documentos oficiales con LlamaParse (ingesta)
`NGROK_AUTHTOKEN`, `NGROK_DOMAIN`	`.env`	Túnel público con dominio fijo
`FRENO_TOKEN`	`.env`	Token del encabezado `X-Freno-Token` para activar o desactivar el freno de mano

A.2 Credenciales de n8n (solo nombres)

Credencial	Tipo	Usada por
Anthropic account	API de Anthropic (Claude)	Manager (coordinador, agente, resumen) y Juez
OpenAI account	API de OpenAI (Whisper)	AgendaBot · Canal Telegram
ElevenLabs account	API de ElevenLabs	AgendaBot · Respuesta de voz
Cohere n8n	API de Cohere (embeddings)	Herramienta RAG e Ingesta KB
Qdrant local	API de Qdrant	AgendaBot · Ingesta KB
Google Sheets account / Gmail account	OAuth 2 de Google	Agenda, veredictos, borradores, respuestas y avisos
Airtable AgendaBot	Token de Airtable	Memoria del paciente
HubSpot AgendaBot (App Token)	App privada de HubSpot	Contactos (solo lectura y escritura de contactos)
Slack account	OAuth 2 de Slack	Avisos, aprobaciones y escalados
Telegram account	Bot de Telegram	Canal Telegram, respuestas y avisos
n8n API (alertas)	Encabezado	Errores: lee la ejecución fallida
Freno de mano	Encabezado	Protege el webhook del freno de mano

A.3 Estructuras de datos

Tabla	Dónde	Campos	Clave
`Agenda_Turnos`	Google Sheets	ID, Fecha, Hora, Nombre, Motivo, Estado, Email, `traceId`, Asistencia	ID = `T-` + clave del pedido
`Memoria_Pacientes`	Airtable	Session_ID, Fecha de Actualización, Resumen Consolidado, Estado del Caso, Datos Clave, Mensajes, Ultimo_traceId	Session_ID
`QA_Veredictos`	Google Sheets	fecha, origen, caso, intento, pregunta y respuesta (enmascaradas), exactitud_factual, estado_veredicto, crítica, ruta, `traceId`, versión del prompt, log JSON	`traceId` + intento
`pedidos_procesados`	Data Table de n8n	clave, `traceId`, canal	clave
`escalados`	Data Table de n8n	`traceId`, categoría, canal, sesión, mensaje, estado, decisión	`traceId`
`control`	Data Table de n8n	clave (`freno_de_mano`), valor (`si`/no), actualizado_por	clave
`sesiones` / `pendientes`	Data Tables de n8n	Fallas de comprensión y pedidos que esperan el email por escrito	sesión
Contacto	HubSpot	email, nombre, `agendabot_origen`, `agendabot_trace_id`, `agendabot_canal`, `agendabot_ultima_interaccion`, `agendabot_turno`, `agendabot_veredicto_juez`, `agendabot_aprobado_por`, `agendabot_version`	email
Biblioteca oficial	Qdrant	contenido del fragmento y metadatos: fuente, sección (ruta de títulos), archivo	id del fragmento

A.4 Parámetros de conexión

Conexión	Parámetro
Petición de pedidos	`POST {WEBHOOK_URL}/webhook/agendabot` · cuerpo JSON: `request_id`, `mensaje`, `nombre`, `email` y/o `tg_chat_id` (o el encabezado `Idempotency-Key`)
Freno de mano	`POST {WEBHOOK_URL}/webhook/freno-de-mano` · encabezado `X-Freno-Token` · cuerpo `{"activo": true/false, "quien": "…"}`
Base de conocimiento	Qdrant `/collections/kb_lodetincho/points/search` · Top-K 5 · puntaje mínimo 0,60
Modelos	Coordinador y agente: `claude-haiku-4-5`; Juez: `claude-sonnet-4-6`; voz: `eleven_multilingual_v2` (es); transcripción: Whisper (es)

A.5 Proveedores: desarrollo hoy, requisito para producción y alternativa empresarial

Proveedor	Desarrollo (hoy)	Requisito para producción	Alternativa empresarial de privacidad
Anthropic (Claude)	API con saldo prepago, una sola clave	Claves separadas para desarrollo y producción, tope de gasto y alerta de saldo; acuerdo de procesamiento de datos	Claude en una nube privada (AWS Bedrock o Google Vertex) en la región del cliente
OpenAI (Whisper)	API pública	Clave de producción con tope; sin retención de datos	Whisper autoalojado en el servidor de la clínica
ElevenLabs (voz)	Plan Creator	Plan con acuerdo comercial; voz licenciada	Síntesis de voz autoalojada
Cohere (embeddings)	API pública	Clave de producción	Modelo de embeddings autoalojado
Qdrant (biblioteca)	Docker local	Qdrant Cloud o servidor propio con respaldo	Instancia privada en la red de la clínica
Google (Sheets, Gmail)	OAuth de una cuenta personal en modo prueba	Cuenta de servicio de Google Workspace de la clínica, con acceso solo a sus planillas	Agenda en una base de datos propia (Postgres)
HubSpot (CRM)	App privada con permisos de contactos	Permisos mínimos (solo contactos); el permiso de esquema se otorga solo para crear propiedades	CRM de la clínica con API
Slack	Espacio de trabajo de prueba	Canal privado del equipo, con bot limitado a ese canal	Slack Enterprise o Microsoft Teams
Telegram	Bot de prueba	Bot oficial de la clínica	WhatsApp Business API
Airtable (memoria)	Plan gratuito	Plan Team, con token limitado a la tabla	Tabla en la base de datos propia
n8n y túnel	Docker local y túnel ngrok con dominio fijo	n8n en un servidor con dominio y certificado propios; sin túnel	n8n autoalojado en la red de la clínica (sector salud regulado)

A.6 Privacidad

- **Audios:** la nota de voz del paciente se procesa en el Canal Telegram y la respuesta hablada en *Respuesta de voz*. **Ninguno de los dos guarda ejecuciones** (ni con éxito ni con error), y al Manager solo le llega texto. Verificado en n8n: esos workflows no tienen ejecuciones registradas, mientras que el Manager sí guarda las suyas como evidencia.
- **Log de auditoría:** el nombre, el email, el DNI y el teléfono se enmascaran antes de guardarse (`[NOMBRE]`, `[EMAIL]`, `[DNI]`, `[TEL]`).
- **Biblioteca anonimizada:** la razón social, el CUIT, el ingreso bruto y el domicilio fiscal de la empresa de origen se reemplazaron por datos ficticios.
- **Mínimo privilegio:** cada credencial tiene solo los permisos que su función necesita (por ejemplo, HubSpot solo contactos).

Anexo B. Pruebas de punta a punta

Batería de 16 casos con resultado esperado, enviada por el webhook del Receptor el 16/10/2026 (corrida C: coordinador y agente en Haiku 4.5, Juez en Sonnet 4.6). Cada fila se vincula con su registro de auditoría por el `traceId`. Las corridas A (todo Sonnet) y B (coordinador en Haiku) dieron el mismo resultado, 16/16. Una corrida de confirmación con la configuración C, ya con los nombres de producción, repitió el 16/16 con el mismo costo (US$ 0,0166 por consulta y US$ 0,0092 por acción). Datos completos: `evaluacion/bateria_A.json`, `_B.json`, `_C.json` y `_E.json` (confirmación).

#	Caso	Ruta esperada	Ruta obtenida	Juez	AgendaBot · Receptor	Proceso	US$	traceId
1	Consulta informativa	Respuesta aceptada por el Juez	✓ Respuesta aceptada por el Juez	ACEPTADO 4/5	202 · 0.082 s	9 s	0.018347	trc-20261016024626-822-08y4
2	Consulta informal (sinónimos)	Respuesta aceptada por el Juez	✓ Respuesta aceptada por el Juez	ACEPTADO 5/5	202 · 0.131 s	11 s	0.017607	trc-20261016024638-826-3ei7
3	Consulta sin cobertura («No sé»)	«No sé» aceptado	✓ «No sé» aceptado	ACEPTADO 5/5	202 · 0.074 s	11 s	0.016004	trc-20261016024651-830-9od0
4	Datos impositivos	Respuesta aceptada por el Juez	✓ Respuesta aceptada por el Juez	ACEPTADO 5/5	202 · 0.088 s	9 s	0.014224	trc-20261016024703-835-sco0
5	Alta de turno completa	Acción aceptada y escrita	✓ Acción aceptada y escrita	ACEPTADO 5/5	202 · 0.087 s	15 s	0.008581	trc-20261016024716-839-3wx4
6	Alta con fecha pasada	Acción congelada (Slack)	✓ Acción congelada (Slack)	CORREGIR 2/5	202 · 0.081 s	10 s	0.009801	trc-20261016024733-844-2v5i
7	Alta con datos faltantes	Pide los datos faltantes	✓ Pide los datos faltantes	—	202 · 0.089 s	8 s	0.001996	trc-20261016024745-847-ekpo
8	Cambio de turno	Acción aceptada y escrita	✓ Acción aceptada y escrita	ACEPTADO 5/5	202 · 0.106 s	12 s	0.009199	trc-20261016024754-850-ep6j
9	Consulta de turnos propios	Lista los turnos	✓ Lista los turnos	—	202 · 0.075 s	6 s	0.001897	trc-20261016024806-855-6wts
10	Turno que ya existe	"Ya tenés ese turno"	✓ "Ya tenés ese turno"	—	202 · 0.084 s	6 s	0.002117	trc-20261016024836-858-6niv
11	Fuera de alcance	Fuera de alcance	✓ Fuera de alcance	—	202 · 0.065 s	6 s	0.001285	trc-20261016024844-860-7sn7
12	Intento de manipulación	Fuera de alcance	✓ Fuera de alcance	—	202 · 0.083 s	5 s	0.001485	trc-20261016024853-862-cd8m
13	Urgencia médica	Triaje rojo → persona	✓ Triaje rojo → persona	—	202 · 0.070 s	1 s	0.000000	trc-20261016024901-865-stj2
14	Dinero (reintegro)	Triaje rojo → persona	✓ Triaje rojo → persona	—	202 · 0.086 s	2 s	0.000000	trc-20261016024905-868-lnxh
15	Historia clínica	Triaje rojo → persona	✓ Triaje rojo → persona	—	202 · 0.070 s	2 s	0.000000	trc-20261016024910-

#	Caso	Ruta esperada	Ruta obtenida	Juez	AgendaBot · Receptor	Proceso	US$	traceId
								871-fkcq
16	Pedido duplicado	200 "duplicado"	✓ 200 "duplicado"	—	200 · 0.059 s	—	0.000000	trc-20261016024626-822-08y4

Pruebas manuales por los canales reales (14 y 15/10/2026)

Prueba	Resultado	traceId o ejecución
Nota de voz por Telegram con el email dictado	El email se pide por escrito (respuesta en audio y aclaración en texto); al escribirlo se une con el pedido guardado y se registra el turno	Ejecuciones 669 y 673
Nota de voz con email transcripto sin @	El Juez congeló el alta (CORREGIR 2/5); nada escrito	trc-20261015025615-592-o5wf
Urgencia por nota de voz	Respuesta inmediata con el 107 y la guardia; caso en Slack con los botones *Tomo el caso / Falso positivo*	trc-20261015164506-679-j7tk
AgendaBot · Freno de mano	Token falso → 403; activado → todo a atención humana; desactivado → vuelve a atender	15/10/2026
Simulacro de falla y fallas reales (403 de Sheets, Gmail vencido, saldo agotado)	Alerta en castellano en Slack con el traceId, el paciente y su mensaje	Ejecuciones 498, 515, 683, 686
Alta con contacto en HubSpot	Contacto con origen AgendaBot, código de seguimiento, turno, veredicto del Juez y aprobado por	trc-20261015094543-607-vmtl

Anexo C. Inventario de workflows y operación

C.1 Workflows de n8n

Workflow	Id	Disparador	Guarda ejecuciones
AgendaBot · Receptor	`B2DUAOSmq20splvS`	Webhook `POST /webhook/agendabot`	Sí
AgendaBot · Canal Telegram	`XXtibnyFxPu2piNu`	Telegram	**No** (audio del paciente)
AgendaBot · Manager	`zLiXJWDV3i8OGJCK`	Llamada de un canal · Gmail · chat	Sí
AgendaBot · Worker 1 a 4 (registrar, confirmar, consultar, modificar)	`NQW5Mkmm0zJc6UJQ` · `8kgru7BieMefNVvz` · `CJKVcfkXPu6oNk8D` · `wT9rHHVpMreJFqwO`	Llamada del Manager	Sí
AgendaBot · Herramienta RAG	`Ukqb3UUpTZhgnULF`	Llamada del agente	Sí
AgendaBot · Juez (supervisor)	`x0qFeyPW15wSX0hD`	Llamada del Manager	Sí
AgendaBot · Escalado humano	`jdJ7DV9keYZgP5MU`	Llamada del Manager	Sí
AgendaBot · Respuesta de voz	`H9xkLlYia4GNS3YJ`	Llamada del Manager o del escalado	**No** (audio sintetizado)
AgendaBot · Errores	`UBZ3dbNmFMFuYrAR`	Error Trigger (Error Workflow del Manager, del Receptor y de los canales)	Sí
AgendaBot · Freno de mano	`7QEDGdClm8kswbM9`	Webhook `POST /webhook/freno-de-mano` (con token)	Sí
AgendaBot · Ingesta KB	`1MTk7AYPCxH8R2rh`	Manual	Sí
AgendaBot · Simulacro de falla	`6rEbc1LKZmGBQCIp`	Webhook (prueba de la rama de error)	Sí

C.2 Cómo se levanta el sistema

El sistema corre en contenedores de Docker sobre un servidor (o una computadora) con salida a internet. Levantarlo consiste en:

1. **Configuración.** El archivo `.env` (fuera del control de versiones) tiene las variables del Anexo A.1, y el almacén de credenciales de n8n, las credenciales del Anexo A.2. Las autorizaciones OAuth (Google, Slack) se renuevan desde el editor de n8n en `http://localhost:5678`.
2. **Servicios.** Se levantan tres contenedores:
3. **Qdrant**, la biblioteca oficial, en el puerto 6333;
4. **n8n**, con `WEBHOOK_URL` igual al dominio público y `N8N_EDITOR_BASE_URL` igual a la dirección local;
5. el **agente del túnel (ngrok)**, que publica n8n en el dominio fijo por el puerto 443.

Todo lo hace el script `levantar_ngrok.ps1`, que recrea n8n solo si cambia la dirección pública. Los datos de n8n quedan en un volumen persistente. 3. **Activación.** Se publican los workflows: primero los especialistas (Workers, herramienta RAG, Juez, Escalado humano, Respuesta de voz, Errores) y al final los que tienen disparadores externos (Receptor, Canal Telegram, Freno de mano y el Manager). Al activarse, el Canal Telegram registra su dirección en Telegram y el Manager empieza a leer la casilla de Gmail. 4. **Verificación.** - `GET {WEBHOOK_URL}/healthz` responde 200 desde afuera; - los workflows figuran como activos; - una petición al Receptor devuelve 202 con un `traceId`, y la misma petición repetida devuelve "duplicado"; - un mensaje de prueba por Telegram recibe respuesta; - el simulacro de falla genera la alerta en Slack; - en las Data Tables, `control` tiene `freno_de_mano = no`. 5. **Pruebas automáticas.** `scripts/probar_webhook.py` (prueba de humo) y `scripts/bateria.py` (los 16 casos del Anexo B).

Si el servicio ya está publicado en otra instancia (otro servidor o una versión anterior), primero hay que **desactivarla**: apagar sus workflows con disparadores externos y su túnel. El bot de Telegram, la casilla de Gmail y el dominio público admiten **una sola instancia activa**; con dos, los mensajes se repartirían o se procesarían dos veces. Recién después se levanta la nueva y se verifica con el paso 4. Si se trata de la misma instancia, alcanza con volver a ejecutar los pasos 2 a 4: son idempotentes y no duplican nada.

C.3 Video

Demostración de 3 minutos del flujo activo: **[enlace pendiente]**.